

REVISIÓN FINAL MODELOS LINEALES

Zaira Rosario Pérez Vázquez

PROBLEMA 1

Los siguientes datos sobre la variable de respuesta Y fueron colectados de un pequeño estudio observacional con variables explicativas X_1, X_2, X_3, X_4 .

X_1	X_2	X_3	X_4	Y_i
5.3	0	65	11.8	22.3
6.2	0	46	10.8	19.7
5.8	1	23	8.1	24.3
12.2	1	77	19.9	23.9
10.0	0	9	10.9	34.6
11.1	0	101	21.2	35.7
8.3	1	45	12.8	32.2
5.4	1	88	14.2	38.1

El modelo propuesto es

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \varepsilon_i$$

Con ε_i no correlacionada y $Var(\varepsilon_i) = \sigma^2$

1. Exprese el modelo en forma matricial, es decir, escriba la matriz diseño X y el vector de parámetros β .

$$Y = X\beta + \varepsilon$$

$$\begin{bmatrix} 22.3 \\ 19.7 \\ 24.3 \\ 23.9 \\ 34.6 \\ 35.7 \\ 32.2 \\ 38.1 \end{bmatrix} = \begin{bmatrix} 1 & 5.3 & 0 & 65 & 11.8 \\ 1 & 6.2 & 0 & 46 & 10.8 \\ 1 & 5.8 & 1 & 23 & 8.1 \\ 1 & 12.2 & 1 & 77 & 19.9 \\ 1 & 10.0 & 0 & 9 & 10.9 \\ 1 & 11.1 & 0 & 101 & 21.2 \\ 1 & 8.3 & 1 & 45 & 12.8 \\ 1 & 5.4 & 1 & 88 & 14.2 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \varepsilon_4 \\ \varepsilon_5 \\ \varepsilon_6 \\ \varepsilon_7 \\ \varepsilon_8 \end{bmatrix}$$

Rcode

```
###Problema 1.
### 0. Capturar información

(Y=matrix(c(22.3,19.7,24.3,23.9,34.6,35.7,32.2,38.1)))
(B0=matrix(c(1,1,1,1,1,1,1,1)))
(x1=matrix(c(5.3,6.2,5.8,12.2,10.0,11.1,8.3,5.4)))
(x2=matrix(c(0,0,1,1,0,0,1,1)))
(x3=matrix(c(65,46,23,77,9,101,45,88)))
(x4=matrix(c(11.8,10.8,8.1,19.9,10.9,21.2,12.8,14.2)))

### 1. Matriz diseño
(matrixX=cbind(B0,x1,x2,x3,x4))
      [,1] [,2] [,3] [,4] [,5]
[1,]    1  5.3    0  65 11.8
[2,]    1  6.2    0  46 10.8
[3,]    1  5.8    1  23  8.1
[4,]    1 12.2    1  77 19.9
[5,]    1 10.0    0   9 10.9
[6,]    1 11.1    0 101 21.2
[7,]    1  8.3    1  45 12.8
[8,]    1  5.4    1  88 14.2
```

2. Encuentre el rango de la matriz X

La matriz X es de rango completo con un valor igual a 4, tanto para la matriz X , como para la matriz $X^t X$.

Rcode

```
### 2. Rango de la matrix X
library(matlib)
R(matrixX)
[1] 4

(XtX=t(matrixX)%*(matrixX))
      [,1] [,2] [,3] [,4] [,5]
[1,]  8.0  64.30  4.0  454.0 109.70
[2,] 64.3 570.27 31.7 3762.3 946.50
[3,]  4.0  31.70  4.0  233.0  55.00
[4,] 454.0 3762.30 233.0 32850.0 7047.30
[5,] 109.7  946.50  55.0  7047.3 1651.23

R(XtX)
[1] 4
```

3. Encuentre la matriz generalizada de X^tX

Rcode

```
###3. Inversa generalizada
(GX=Ginv(XtX))
      [,1] [,2]      [,3]      [,4]      [,5]
[1,]  1.70368198    0 -0.26509395  0.00855274 -0.14085711
[2,] -0.14085711    0  0.00531387 -0.00225674  0.01941806
[3,] -0.26509395    0  0.50272761 -0.00104205  0.00531387
[4,] -0.00553297    0 -0.00051066  0.00017809 -0.00031493
[5,]  0.00000000    0  0.00000000  0.00000000  0.00000000
```

4. Encuentre el estimador de mínimos cuadrados $\hat{\beta}$ de β .

En el caso de X con rango completo, la solución de las ecuaciones normales es única y resulta como $\hat{\beta} = (X^tX)^{-1}X^tY$.

Rcode

```
###4. Estimar beta con MCO
(betas=GX%*%t(matrizX)%*%(Y))
      [,1]
[1,] 21.29089672
[2,]  0.54014232
[3,]  1.54219122
[4,]  0.04307034
[5,]  0.00000000
```

5. Muestre que β_1 no es estimable

Utilizando el Teorema 1 sobre estimabilidad, sea $Y = X\beta + \varepsilon$ un modelo lineal donde $\varepsilon \sim N(0, \sigma^2 I)$. Entonces $\lambda^t \beta$ es estimable si y sólo si hay una solución del sistema lineal $\lambda^t (X^tX)^- X^tX = \lambda^t$ para cualquier inversa generalizada $(X^tX)^-$. Si se define como $\lambda_1^t = (0 \ 1 \ 0 \ 0 \ 0)$, al aplicar el teorema 1 se obtiene que $\lambda_1^t (X^tX)^- X^tX \neq \lambda_1^t$, por lo tanto λ_1^t no es estimable.

Rcode

```
###5. Muestre que B1 es no estable
(lambda1=matrix(c(0,1,0,0,0)))
      [,1]
[1,]    0
[2,]    1
[3,]    0
[4,]    0
[5,]    0
(lambda1_t=t(lambda1))
      [,1] [,2] [,3] [,4] [,5]
[1,]    0    1    0    0    0

#Probando estimabilidad con el teorema 1
round(lambda1_t%%GX%%XtX) #No es estimable
      [,1] [,2] [,3] [,4] [,5]
[1,]    0    1    0    0    1
```

Utilizando el teorema 2 sobre estimabilidad, sea $Y = X\beta + \varepsilon$ un modelo lineal donde $\varepsilon \sim N(0, \sigma^2 I)$. Entonces $\lambda^t \beta$ es estimable si y solo si λ^t pertenece al espacio de renglones de X o $(X^t X)$. Si $R(X) = R(X^t X)$ es igual al rango $R\left(\begin{smallmatrix} X \\ \lambda^t \end{smallmatrix}\right)$ entonces $\lambda^t \beta$ es estimable. Se estimaron los rangos de cada matriz y se obtuvo que $R(X) = R(X^t X) \neq R\left(\begin{smallmatrix} X \\ \lambda_1^t \end{smallmatrix}\right) \rightarrow 4 = 4 \neq 5$, por lo tanto, λ_1^t no es estimable.

Rcode

```
R(matrizX)
[1] 4
R(XtX)
[1] 4
(X_lambda1=rbind(matrizX,lambda1_t))
      [,1] [,2] [,3] [,4] [,5]
[1,]    1  5.3    0   65 11.8
[2,]    1  6.2    0   46 10.8
[3,]    1  5.8    1   23  8.1
[4,]    1 12.2    1   77 19.9
[5,]    1 10.0    0    9 10.9
[6,]    1 11.1    0  101 21.2
[7,]    1  8.3    1   45 12.8
[8,]    1  5.4    1   88 14.2
[9,]    0  1.0    0    0  0.0
R(X_lambda1) #No es estimable
[1] 5
```

6. Muestre que $\theta = \beta_1 + 2\beta_2 + \beta_4$ es estimable y encuentre su estimador de mínimos cuadrados $\hat{\theta}$

Se repitió el procedimiento anterior, por lo que ahora se definió como $\lambda_2^t = (0 \ 1 \ 2 \ 0 \ 1)$ y se verificó su estimabilidad utilizando el teorema 1 y 2. De acuerdo con el teorema 1: $\lambda_2^t(X^T X)^- X^t X = \lambda_2^t$, y de acuerdo con el teorema 2: $R(X) = R(X^t X) \neq R\left(\begin{smallmatrix} X \\ \lambda_2^t \end{smallmatrix}\right) \rightarrow 4 = 4 \neq 5$, se concluye que es estimable λ_2^t .

Rcode

###7. Muestre que theta2=b1+2b2+b4 es estimable y encuentre estimador de MCO

```
lambda2=matrix(c(0,1,2,0,1))
```

```
  [,1]
```

```
[1,] 0
```

```
[2,] 1
```

```
[3,] 2
```

```
[4,] 0
```

```
[5,] 1
```

```
(lambda2_t=t(lambda2))
```

```
  [,1] [,2] [,3] [,4] [,5]
```

```
[1,] 0 1 2 0 1
```

#Probando estimabilidad con el teorema 1

```
round(lambda2_t*%GX*%XtX) #Es estimable
```

```
  [,1] [,2] [,3] [,4] [,5]
```

```
[1,] 0 1 2 0 1
```

#Probando estimabilidad con el teorema 2

```
R(matrizX)
```

```
[1] 4
```

```
R(XtX)
```

```
[1] 4
```

```
(X_lambda2=rbind(matrizX,lambda2_t))
```

```
  [,1] [,2] [,3] [,4] [,5]
```

```
[1,] 1 5.3 0 65 11.8
```

```
[2,] 1 6.2 0 46 10.8
```

```
[3,] 1 5.8 1 23 8.1
```

```
[4,] 1 12.2 1 77 19.9
```

```
[5,] 1 10.0 0 9 10.9
```

```
[6,] 1 11.1 0 101 21.2
```

```
[7,] 1 8.3 1 45 12.8
```

```
[8,] 1 5.4 1 88 14.2
```

```
[9,] 0 1.0 2 0 1.0
```

```
R(X_lambda2) #Es estimable
```

```
[1] 4
```

```
Rcode
```

```
###Otra forma de verificar si sono o no estimables las funciones anteriores
library(estimability)
N=nonest.basis(matrizX)
funciones<-rbind(c(0,1,0,0,0),
                  c(0,1,2,0,1))
is.estble(funciones,N)
[1] FALSE TRUE
```

En virtud de que θ es una función estimable, es posible obtener $\hat{\theta}$ mediante mínimos cuadrados. El estimador de mínimos cuadrados de una función estimable $\lambda^t \beta$ es estimable, entonces $\lambda^t \hat{\beta} = \lambda^t \tilde{\beta}$ para cualquiera de dos soluciones $\hat{\beta}$ y $\tilde{\beta}$ de las ecuaciones normales $X^t X \beta = X^t Y$.

```
Rcode
```

```
### 8. Hallar el estimador de MCO
(MCO1=lambda2_t*%%betas) #ES MELI
      [,1]
[1,] 3.624525

#Verificando
betas[2]+2*betas[3]+betas[5]
[1] 3.62452
```

7. Encuentre la varianza de $\hat{\theta}$.

Como la matriz X es de rango completo, se puede aplicar el teorema de Gauss-Marcov que indica que si θ es estimable, entonces el estimador de MCO $\hat{\theta}$ de θ es el mejor estimador lineal insesgado (MELI) de θ . Para estimar la varianza se aplicó el siguiente teorema:

Sea $R(X) = r$ el rango de X y $Cov(\epsilon) = \sigma^2 I$. Entonces $\frac{(Y^t(1-M)Y)}{(n-r)}$ es un estimador insesgado de σ^2 . Donde $M = X(X^t X)^{-1} X^t$. Es decir, $\sigma^2 = \frac{(Y^t(1-M)Y)}{(n-r)} = \frac{(Y-X\hat{\beta})^t(Y-X\hat{\beta})}{(n-r)}$. En la práctica se puede asumir bajo estos criterios que $\hat{\sigma}^2 = CME$, el cuadrado medio del error estima a $\hat{\sigma}^2$.

Code

```
### 9. Estimando sigma^2 = CME
#Aplicando el teorema de Gauss Marcov
(MELI1=MC01)

#CME=((Y-X beta_hat)'(Y-X beta_hat))/(n-r)
CME=(t(Y-(matrizX%%betas))%*(Y-(matrizX%%betas)))/(length(Y)-R(matrizX))
CME
      [,1]
[1,] 77.43848
```

Por lo cual, $\hat{\sigma}^2 = CME = 77.43$

Ahora, para estimar la varianza de $\hat{\theta}$ se utiliza el siguiente teorema:

En un modelo $Y = X\beta + \varepsilon$, donde $E(\varepsilon)$ se distribuye $N(0, \sigma^2 I)$ y que $\lambda^t \beta$ es estimable. Entonces, $\lambda^t \hat{\beta}$ se distribuye normal con media $\lambda^t \beta$ y varianza $\lambda^t (X^t X)^{-1} \lambda \sigma^2$. Por lo cual, $\lambda^t \hat{\beta}$ y CME son independientemente distribuidos y estimadores insesgados uniformes de varianza mínima de $\lambda^t \beta$ y de σ^2 .

$$Var(\hat{\theta}) = 158.8715$$

Code

```
### 9. Estimando sigma^2 = CME
#Aplicando el teorema de Gauss Marcov
(MELI1=MC01)

#CME=((Y-X beta_hat)'(Y-X beta_hat))/(n-r)
CME=(t(Y-(matrizX%%betas))%*(Y-(matrizX%%betas)))/(length(Y)-R(matrizX))
CME
      [,1]
[1,] 77.43848
sqrt(CME)
      [,1]
[1,] 8.799913 #Coincide con el summary de lm

#Estimando la varianza de theta
#lambda'(X' X)^-1 lambda sigma^2
(lambda2_t%%GX%%lambda2)*CME
      [,1]
[1,] 158.8715
```

8. Escriba la forma de $100(1 - \alpha)\%$ un intervalo de confianza para θ .

Un intervalo de confianza del $(1 - \alpha)100\%$ para $\lambda^t \beta$ es

$$\lambda \hat{\beta} \pm \sqrt{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]} \times t_{\frac{\alpha}{2}, (n-r)}.$$

Donde $t_{\frac{\alpha}{2}, (n-r)}$. Se obtiene de las tablas t de student.

Con un intervalo de confianza del 95%, θ se encuentra entre -31.37 y 38.62. Como el intervalo de confianza incluye al cero, se concluye que no hay un efecto lineal.

Code

```
### 10. Intervalos de confianza para theta
(ts=qt(1-0.05/2,8-4))
[1] 2.776445

#Aplicando la formula en partes
#Lambda2*beta_hat +- raiz((lambda2_t*GX*lambda*CME)) * ts
parte1=lambda2_t*GX*lambda2
parte2=sqrt(parte1*CME)
parte3=parte2*ts
MELI1

(Ic1=MELI1+parte3)
      [,1]
[1,] 38.62002

(Ic2=MELI1-parte3)
      [,1]
[1,] -31.37097
```

9. Prueba que $H_0 = \theta = 0$ vs $H_a: \theta \neq 0$ utilizando la prueba F con un $\alpha = 0.05$.

Cuando $A = \lambda^t$, un estadístico de prueba para contrastar hipótesis $H_0 = \lambda^t \beta = m$ vs $H_a: \lambda^t \beta \neq m$ es:

$$Tc = \frac{\lambda \hat{\beta} - m}{\sqrt{[(\lambda^t (X^t X)^{-1} \lambda) \times CME]}}$$

Donde $m = 0$, como $|Tc|$ es pequeño entonces no se rechaza H_0 , por lo tanto $\theta = 0$

Code

```
### 11. Prueba de hipotesis Ho= theta igual a 0
(Tc=(MELI1-0)/parte2)
      [,1]
[1,] 0.2875597

Ts
[1] 2.776445

#No se rechaza Ho
```

PROBLEMA 2

Marcuse (1949) registró el contenido de humedad de tres tipos de queso elaborado mediante dos métodos diferentes. Se midieron dos piezas de queso para tipo y método. Los datos se muestran a continuación

Tratamiento				Mediciones del contenido de humedad			
Tipo	A	Hecho con el método	1	Y_{11}	=	39.02	Y_{12} = 38.8
Tipo	B	Hecho con el método	1	Y_{21}	=	35.74	Y_{22} = 35.4
Tipo	C	Hecho con el método	1	Y_{31}	=	37.02	Y_{32} = 36.0
Tipo	A	Hecho con el método	2	Y_{41}	=	38.96	Y_{42} = 39.0
Tipo	B	Hecho con el método	2	Y_{51}	=	35.58	Y_{52} = 35.5
Tipo	C	Hecho con el método	2	Y_{61}	=	35.70	Y_{62} = 36.0

Considere el modelo $Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$, donde $\varepsilon_{ij} \sim NID(0, \sigma^2)$, $i = 1, 2, 3, 4, 5, 6$ y $j = 1, 2$.

Este modelo puede ser expresado en forma matricial como

$$\begin{bmatrix} Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{22} \\ Y_{31} \\ Y_{32} \\ Y_{41} \\ Y_{42} \\ Y_{51} \\ Y_{52} \\ Y_{61} \\ Y_{62} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{bmatrix} + \begin{bmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{21} \\ \varepsilon_{22} \\ \varepsilon_{31} \\ \varepsilon_{32} \\ \varepsilon_{41} \\ \varepsilon_{42} \\ \varepsilon_{51} \\ \varepsilon_{52} \\ \varepsilon_{61} \\ \varepsilon_{62} \end{bmatrix}$$

1. Obtenga la distribución de Y

Considerando la siguiente notación con $n = 2$:

Factor A: tipo de queso ($a = 3$)

Factor B: método de elaboración ($b = 2$)

El modelo previamente planteado considera las interacciones entre los factores A y B, pero podría ser expresado como un modelo de dos vías con efecto de interacción de la siguiente forma:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \gamma_{ij} + \varepsilon_{ijk} \quad (1)$$

El efecto del factor A (tipo de queso) en el i-ésimo nivel es α_i y el término β_j representa el efecto del j-ésimo del factor B (método de elaboración). El término γ_{ij} representa la interacción AB entre el i-ésimo nivel de A y el j-ésimo nivel de B. Si $y \sim N_{abn}(X\beta, \sigma^2 I)$ la suma de cuadrados del factor A, B y su interacción son independientes.

Al sumar las dos mediciones realizadas para cada interacción entre el factor A y B y sus valores totales, se obtiene:

Factor A: Método de elaboración	Factor B: Tipo de queso			Total
	Queso A	Queso B	Queso C	
Método 1	$Y_{11} = 77.82$	$Y_{12} = 71.14$	$Y_{13} = 73.02$	$Y_{met1} = 221.98$
Método 2	$Y_{21} = 77.96$	$Y_{22} = 71.08$	$Y_{23} = 71.74$	$Y_{met2} = 220.78$
Total	$Y_{QA} = 155.78$	$Y_{QB} = 142.22$	$Y_{QC} = 144.76$	$Y_{total} = 442.76$

La suma de cuadrados para el factor A “tipo de queso” se obtiene:

$$\begin{aligned}
 SS_{FB} &= \sum_{j=1}^b \frac{(y_{Qj})^2}{(b)(n)} - \frac{(y_{total})^2}{(a)(b)(n)} \\
 &= \frac{(155.78)^2 + (142.22)^2 + (144.76)^2}{2 \times 2} - \frac{(442.76)^2}{3 \times 2 \times 2} = 25.99
 \end{aligned}$$

La suma de cuadrados para factor B “método de elaboración” se obtiene

$$\begin{aligned}
 SS_{FA} &= \sum_{l=1}^a \frac{(y_{metl})^2}{(a)(n)} - \frac{(y_{total})^2}{(a)(b)(n)} \\
 &= \frac{(221.98)^2 + (220.81)^2}{3 \times 2} - \frac{(442.76)^2}{2 \times 3 \times 2} = 0.12
 \end{aligned}$$

Code

```
#Suma de cuadrados para factor A (tipo de queso)
(((155.78^2)+(142.22^2)+(144.76^2))/4)-((442.76^2)/12)
[1] 25.98047
#Suma de cuadrados para factor B (metodo de elaboración)
(((221.98^2)+(220.78^2))/6)-((442.76^2)/(3*2*2))
[1] 0.12
```

La suma de cuadrados del error se obtiene:

$$SSE = \sum_{ijk} (y_{ijk})^2 - \sum_{ij} \frac{(y_{ij})^2}{n} = 0.651$$

Para un modelo de dos vías, $Var(\varepsilon_{ijk}) = \sigma^2$. Para estimar $\sigma^2 = \frac{SSE}{ab(n-1)} = \frac{0.651}{(3)(2)(2-1)} = 0.1085$

Code

```
#Formas cuadraticas
Y
(J=matrix(1,nrow(X_full),nrow(X_full)))
(I=diag(1,nrow(X_full)))
(n=nrow(X_full))
(PX=X_full%*%ginv(t(X_full)%*%X_full)%*%t(X_full))

#Suma de cuadrados del error
(SCE=t(Y)%*%(I-PX)%*%Y)
      [,1]
[1,] 0.6512
#Grados de libertad del error
(gle=R(I-PX))
[1] 6
```

La suma de cuadrados totales está dada por

$$SST = \sum_{ijk} (y_{ijk})^2 - \frac{(Y_{total})^2}{a \times b \times n} = 27.1298$$

Code

```
> #Suma de cuadrados del modelo
> (SCM=t(Y)%*(PX-(1/n)*J)%*Y)
      [,1]
[1,] 26.47867
> #Grados de libertad del modelo
> (glm=R(PX-(1/n)*J))
[1] 5
> #Suma de cuadrados total corregida
> (SCT=t(Y)%*(I-(1/n)*J)%*Y)
      [,1]
[1,] 27.12987
> #Grados de libertad totales
> (glm=R(I-(1/n)*J)) #Son 12 observaciones
[1] 11
```

La suma de cuadrados de la interacción se obtiene por diferencia:

$$SS_{interacción} = SST - SS_{FA} - SS_{FB} - SSE =$$

$$SS_{interacción} = 0.3$$

Para obtener la distribución de Y , se considera la suma de cuadrados del error:

$$SCE = Y^t(I - PX)Y$$

Dividiendo por σ^2 :

$$\frac{Y^t(I - PX)Y}{\sigma^2} = Y^tAY$$

Con

$$A = \frac{1}{\sigma^2} \left(I - \frac{1}{n} J \right)$$

$$Y^tAY \sim \chi^2_{N-R}(\lambda)$$

$$Y^tAY \sim \chi^2_{12-6}(\lambda)$$

Con

$$\lambda = \frac{1}{2} \mu^t A \mu$$

$$\lambda = \frac{1}{2} (X\beta)^t \left(\frac{I - PX}{\sigma^2} \right) X\beta$$

2. Estime los parámetros del modelo utilizando inversas generalizadas.

El modelo planteado $Y_{ij} = \mu + \alpha_i + \epsilon_{ij}$, donde $\epsilon_{ij} \sim NID(0, \sigma^2)$, $i = 1, 2, 3, 4, 5, 6$ y $j = 1, 2$ es un modelo reducido en el que i representa la interacción entre el tipo de queso y el método de elaboración, mientras que j representa el número de mediciones. El modelo anterior puede ser expresado en forma $Y = X\beta + e$ de la siguiente forma:

$$\begin{bmatrix} 39.02 \\ 38.8 \\ 35.74 \\ 35.4 \\ 37.02 \\ 36.0 \\ 38.96 \\ 39.0 \\ 35.58 \\ 35.5 \\ 35.7 \\ 36.0 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{bmatrix} + \begin{bmatrix} \epsilon_{11} \\ \epsilon_{12} \\ \epsilon_{21} \\ \epsilon_{22} \\ \epsilon_{31} \\ \epsilon_{32} \\ \epsilon_{41} \\ \epsilon_{42} \\ \epsilon_{51} \\ \epsilon_{52} \\ \epsilon_{61} \\ \epsilon_{62} \end{bmatrix}$$

Se utilizó la librería MASS para obtener la inversa generalizada X^tX . Resolviendo las ecuaciones normales del método de mínimos cuadrados $\hat{\beta} = (X^tX)^{-}X^tY$, se obtuvo lo siguiente:

$$\begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{bmatrix} = \begin{bmatrix} 31.622 \\ 7.287 \\ 3.947 \\ 4.887 \\ 7.357 \\ 3.917 \\ 4.227 \end{bmatrix}$$

Code

```
### 2. Escribe los parámetros del modelo utilizando inversas generalizadas
library(matlib)
library(MASS)
# Rango de X
R(X)
[1] 6
# Rango de X'X
(XtX=t(X)%*%X)
      MU ALPHA1 ALPHA2 ALPHA3 ALPHA4 ALPHA5 ALPHA6
MU    12      2      2      2      2      2      2
ALPHA1 2      2      0      0      0      0      0
ALPHA2 2      0      2      0      0      0      0
```

```

Code
ALPHA3 2 0 0 2 0 0 0
ALPHA4 2 0 0 0 2 0 0
ALPHA5 2 0 0 0 0 2 0
ALPHA6 2 0 0 0 0 0 2
R(XtX)
[1] 6

# Inversa generalizada de X'X (libreria MASS)
(G_XtX=ginv(XtX))
      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]      [,7]
[1,] 0.06122449 0.01020408 0.01020408 0.01020408 0.01020408 0.01020408 0.01020408
[2,] 0.01020408 0.41836735 -0.08163265 -0.08163265 -0.08163265 -0.08163265 -0.08163265
[3,] 0.01020408 -0.08163265 0.41836735 -0.08163265 -0.08163265 -0.08163265 -0.08163265
[4,] 0.01020408 -0.08163265 -0.08163265 0.41836735 -0.08163265 -0.08163265 -0.08163265
[5,] 0.01020408 -0.08163265 -0.08163265 -0.08163265 0.41836735 -0.08163265 -0.08163265
[6,] 0.01020408 -0.08163265 -0.08163265 -0.08163265 -0.08163265 0.41836735 -0.08163265
[7,] 0.01020408 -0.08163265 -0.08163265 -0.08163265 -0.08163265 -0.08163265 0.41836735

# Estimacion de parametros MCO
(alphas=G_XtX%%t(X)%%Y) #Esta solución no es única
      [,1]
[1,] 31.622857
[2,] 7.287143
[3,] 3.947143
[4,] 4.887143
[5,] 7.357143
[6,] 3.917143
[7,] 4.227143

```

3. Determine cuál de los juegos de hipótesis se pueden probar (es decir, son estimables)

a. $H_0: \alpha_1 = \alpha_2 = \alpha_3$

La hipótesis se puede expresar en términos matriciales, de la siguiente forma:

$$R_1 = \begin{bmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{bmatrix}$$

$$H_0 = \begin{bmatrix} 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{bmatrix} = \begin{bmatrix} \alpha_1 - \alpha_2 \\ \alpha_1 - \alpha_3 \end{bmatrix}$$

$$X_{R1} = \begin{bmatrix} X \\ R_1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & -1 & 0 & 0 & 0 \end{bmatrix}$$

Para identificar si R_2 es estimable, se verificó que $R(X) = R\left(\begin{smallmatrix} X \\ R_1 \end{smallmatrix}\right) \rightarrow 6 = 6$, por lo tanto, la combinación lineal R_1 sí es estimable.

Code

```
### 3. Son estimables?
# a) Ho: a1=a2=a3
(R1=rbind(c(0,1,-1,0,0,0,0),
           c(0,1,0,-1,0,0,0)))
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    0    1   -1    0    0    0    0
[2,]    0    1    0   -1    0    0    0
(XR1=rbind(X,R1))
      MU ALPHA1 ALPHA2 ALPHA3 ALPHA4 ALPHA5 ALPHA6
[1,]    1     1     0     0     0     0     0
[2,]    1     1     0     0     0     0     0
[3,]    1     0     1     0     0     0     0
[4,]    1     0     1     0     0     0     0
[5,]    1     0     0     1     0     0     0
[6,]    1     0     0     1     0     0     0
[7,]    1     0     0     0     1     0     0
[8,]    1     0     0     0     1     0     0
[9,]    1     0     0     0     0     1     0
[10,]   1     0     0     0     0     1     0
[11,]   1     0     0     0     0     0     1
[12,]   1     0     0     0     0     0     1
[13,]   0     1    -1     0     0     0     0
[14,]   0     1     0    -1     0     0     0
R(X)
[1] 6
R(XR1) #Es estimable
[1] 6
```


Posteriormente se obtuvo $R\hat{\beta}$, se observa que el diferencial no es cercano a 0.

Code

```
#Valores
(R1Beta=R1%*%alphas)
      [,1]
[1,]  3.34
[2,]  2.40
```

El estadístico de prueba F se calculó de la siguiente forma

Code

```
#Prueba de F
(numerador=t(R1Beta)%*%inv(R1%*%G_XtX%*%t(R1))%*%R1Beta)
      [,1]
[1,] 11.86613
(rangonumerador=R(inv(R1%*%G_XtX%*%t(R1))))
[1] 2
PX=X%*%G_XtX%*%t(X)
R(PX)
[1] 6
I=as.matrix(diag(nrow(X)))
(denominador=t(Y)%*%(I-PX)%*%Y)
      [,1]
[1,] 0.6512
(rangodenominador=R(I)-R(PX))
[1] 6
(Fc=(numerador/rangonumerador)/(denominador/rangodenominador))
      [,1]
[1,] 54.66585
(Ftabla=qf(1-0.05,rangonumerador,rangodenominador))
[1] 5.143253
(pvalue=1-pf(Fc,rangonumerador,rangodenominador))
      [,1]
[1,] 0.0001408016
```

Con un $\alpha = 0.05$ y un valor $F_{calc} = 54.66$ superior a $F_{tablas} = 5.14$, se rechaza que $H_0: \alpha_1 = \alpha_2 = \alpha_3$ y con un $p_{value} = 0.00014$.

b. $H_0 = \alpha_1 = \alpha_2 = \alpha_3 = 0$

La hipótesis se puede expresar en términos matriciales como:

$$R_2 = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

$$H_0 = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{bmatrix} = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$X_{R_2} = \begin{bmatrix} X \\ R_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

Para identificar si R_2 es estimable, se verificó que $R(X) = R \begin{pmatrix} X \\ R_2 \end{pmatrix} \rightarrow 6 \neq 7$, por lo tanto, la combinación lineal R_2 no es estimable.

Code

```
# b) Ho: a1=a2=a3=0
(R2=rbind(c(0,1,0,0,0,0,0),
           c(0,0,1,0,0,0,0),
           c(0,0,0,1,0,0,0)))
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    0    1    0    0    0    0    0
[2,]    0    0    1    0    0    0    0
[3,]    0    0    0    1    0    0    0
```

```
Code
(XR2=rbind(X,R2))
      MU ALPHA1 ALPHA2 ALPHA3 ALPHA4 ALPHA5 ALPHA6
[1,]  1      1      0      0      0      0      0
[2,]  1      1      0      0      0      0      0
[3,]  1      0      1      0      0      0      0
[4,]  1      0      1      0      0      0      0
[5,]  1      0      0      1      0      0      0
[6,]  1      0      0      1      0      0      0
[7,]  1      0      0      0      1      0      0
[8,]  1      0      0      0      1      0      0
[9,]  1      0      0      0      0      1      0
[10,] 1      0      0      0      0      1      0
[11,] 1      0      0      0      0      0      1
[12,] 1      0      0      0      0      0      1
[13,] 0      1      0      0      0      0      0
[14,] 0      0      1      0      0      0      0
[15,] 0      0      0      1      0      0      0
R(X)
[1] 6
R(XR2) #No es estimable
[1] 7
```

c. $H_0 = \mu + \alpha_1 = 39 \quad \text{y} \quad \mu + \alpha_4 = 39$

La hipótesis se puede expresar en términos matriciales como:

$$R_3 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

$$H_0 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{bmatrix} = \begin{bmatrix} \mu + \alpha_1 \\ \mu + \alpha_4 \end{bmatrix} = \begin{bmatrix} 39 \\ 39 \end{bmatrix}$$

$$H_0: R\hat{\beta} = r \Leftrightarrow H_0: R\hat{\beta} - r = 0$$

$$\therefore H_0: R\hat{\beta} - 39 = 0$$

$$X_{R3} = \begin{bmatrix} X \\ R_3 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

Para identificar si R_3 es estimable, se verificó que $R(X) = R\left(\begin{smallmatrix} X \\ R_3 \end{smallmatrix}\right) \rightarrow 6 = 6$, por lo tanto, la combinación lineal R_3 sí es estimable.

Code

```
# c) Ho: m+a1=39 & m+a4=39
(R3=rbind(c(1,1,0,0,0,0,0),
           c(1,0,0,0,1,0,0)))
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    1    1    0    0    0    0    0
[2,]    1    0    0    0    1    0    0
(XR3=rbind(X,R3))
      MU ALPHA1 ALPHA2 ALPHA3 ALPHA4 ALPHA5 ALPHA6
[1,]    1      1      0      0      0      0      0
[2,]    1      1      0      0      0      0      0
[3,]    1      0      1      0      0      0      0
[4,]    1      0      1      0      0      0      0
[5,]    1      0      0      1      0      0      0
[6,]    1      0      0      1      0      0      0
[7,]    1      0      0      0      1      0      0
[8,]    1      0      0      0      1      0      0
[9,]    1      0      0      0      0      1      0
[10,]   1      0      0      0      0      1      0
[11,]   1      0      0      0      0      0      1
[12,]   1      0      0      0      0      0      1
[13,]   1      1      0      0      0      0      0
[14,]   1      0      0      0      1      0      0
R(X)
[1] 6
R(XR3) #Si es estimable
[1] 6
```

Posteriormente se obtuvo $R\hat{\beta} - 39$, se observa que el diferencial es muy cercano a 0.

Code

```
#Bajo la hipotesis Ho:Rbeta=r --> Ho:Rbeta-r=0
#Valores
(R3Beta=(R3%%alphas)-39)
      [,1]
[1,] -0.09
[2,] -0.02
```

El estadístico de prueba F se calculó de la siguiente forma

Code

```
#Prueba de F
(numerador3=t(R3Beta)%%inv(R3%%G_XtX%%t(R3))%%R3Beta)
      [,1]
[1,] 0.017
(rangonumerador3=R(inv(R3%%G_XtX%%t(R3))))
[1] 2
PX=X%%G_XtX%%t(X)
R(PX)
[1] 6
I=as.matrix(diag(nrow(X)))
(denominador=t(Y)%%(I-PX)%%Y)
      [,1]
[1,] 0.6512
(rangodenominador=R(I)-R(PX))
[1] 6
(Fc3=(numerador3/rangonumerador3)/(denominador/rangodenominador))
      [,1]
[1,] 0.07831695
(Ftabla3=qf(1-0.05,rangonumerador3,rangodenominador))
[1] 5.143253
(pvalue3=1-pf(Fc3,rangonumerador3,rangodenominador))
      [,1]
[1,] 0.9256
```

Con un $\alpha = 0.05$ y un valor $F_{calc} = 0.0783$ inferior a $F_{tablas} = 5.1432$ no rechaza que $H_0 = \mu + \alpha_1 = 39$ y $\mu + \alpha_4 = 39$ y con un $p_{value} = 0.9256$.

$$d. H_0: \begin{pmatrix} 0 & 1 & -1 & 0 & -1 & 1 & 0 \\ 0 & 1 & 0 & -1 & -1 & 0 & 1 \end{pmatrix} \beta = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

La hipótesis se puede expresar en términos matriciales como:

$$R_4 = \begin{bmatrix} 0 & 1 & -1 & 0 & -1 & 1 & 0 \\ 0 & 1 & 0 & -1 & -1 & 0 & 1 \end{bmatrix}$$

$$H_0 = \begin{bmatrix} 0 & 1 & -1 & 0 & -1 & 1 & 0 \\ 0 & 1 & 0 & -1 & -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \alpha_4 \\ \alpha_5 \\ \alpha_6 \end{bmatrix} = \begin{bmatrix} \alpha_1 - \alpha_2 + \alpha_5 - \alpha_4 \\ \alpha_1 - \alpha_3 + \alpha_6 - \alpha_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$X_{R3} = \begin{bmatrix} X \\ R_4 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & -1 & 0 & -1 & 1 & 0 \\ 0 & 1 & 0 & -1 & -1 & 0 & 1 \end{bmatrix}$$

Para identificar si R_4 es estimable, se verificó que $R(X) = R \begin{pmatrix} X \\ R_4 \end{pmatrix} \rightarrow 6 = 6$, por lo tanto, la combinación lineal R_4 sí es estimable.

Code

```
# d) Ho: 0 1 -1 0 -1 1 0      beta=0
#          0 1 0 -1 -1 0 1      0
(R4=rbind(c(0,1,-1,0,-1,1,0),
           c(0,1,0,-1,-1,0,1)))
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    0    1   -1    0   -1    1    0
[2,]    0    1    0   -1   -1    0    1

(XR4=rbind(X,R4))
      MU ALPHA1 ALPHA2 ALPHA3 ALPHA4 ALPHA5 ALPHA6
[1,]    1      1      0      0      0      0      0
[2,]    1      1      0      0      0      0      0
```

```

Code
[3,] 1 0 1 0 0 0 0
[4,] 1 0 1 0 0 0 0
[5,] 1 0 0 1 0 0 0
[6,] 1 0 0 1 0 0 0
[7,] 1 0 0 0 1 0 0
[8,] 1 0 0 0 1 0 0
[9,] 1 0 0 0 0 1 0
[10,] 1 0 0 0 0 1 0
[11,] 1 0 0 0 0 0 1
[12,] 1 0 0 0 0 0 1
[13,] 0 1 -1 0 -1 1 0
[14,] 0 1 0 -1 -1 0 1
R(X)
[1] 6
R(XR4) #Es estimable
[1] 6

```

Posteriormente se obtuvo $R\hat{\beta}$, se observa que el diferencial es cercano a 0.

```

Code

#Valores
(R4Beta=R4%%alphas)
      [,1]
[1,] -0.10
[2,] -0.73

```

El estadístico de prueba F se calculó de la siguiente forma

```

Code

#Prueba de F
( Numerador4=t(R4Beta)%%inv(R4%%G_XtX%%t(R4))%%R4Beta)
      [,1]
[1,] 0.3132667
(rangonumerador4=R(inv(R4%%G_XtX%%t(R4))))
[1] 2
PX=X%%G_XtX%%t(X)
R(PX)
[1] 6
I=as.matrix(diag(nrow(X)))
(denominador=t(Y)%%(I-PX)%%Y)
      [,1]
[1,] 0.6512
(rangodenominador=R(I)-R(PX))
[1] 6

```

Code

```
(Fc4=(numerador4/rangonumerador4)/(denominador/rangodenominador))
      [,1]
[1,] 1.443182
(Ftabla4=qf(1-0.05,rangonumerador4,rangodenominador))
[1] 5.143253
(pvalue=1-pf(Fc4,rangonumerador4,rangodenominador))
      [,1]
[1,] 0.3078091
```

Con un $\alpha = 0.05$ y un valor $F_{calc} = 1.44$ inferior a $F_{tablas} = 5.1432$ no rechaza que $H_0 = \alpha_1 - \alpha_2 + \alpha_5 - \alpha_4 = 0$ y $\alpha_1 - \alpha_3 + \alpha_6 - \alpha_4 = 0$ y con un $p_{value} = 0.3078$.

4. Exprese las siguientes hipótesis en la forma $H_0: Cb = 0$. Si la hipótesis se puede probar, realice la prueba de F, obtenga el pvalue y escriba su conclusión.

- a. **Después de promediar por métodos de elaboración de queso, el contenido de humedad promedio es la misma en los tres tipos de queso (probar efecto de tipo de queso).**
- b. **Por cada tipo de queso, la humedad promedio no es afectada por el método de elaboración (probar efecto de método).**

4.1. Identificación de las combinaciones lineales y estimabilidad

Considerando la siguiente notación con $n = 2$:

Factor A: Tipo de queso ($a = 3$)

Factor B: tipo de queso ($b = 2$)

El modelo previamente planteado considera las interacciones entre los factores A y B, pero podría ser expresado como un modelo de dos vías con efecto de interacción de la siguiente forma:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \gamma_{ij} + \varepsilon_{ijk} \quad (1)$$

El efecto del factor A (tipo de queso) en el i -ésimo nivel es α_i y el término β_j representa el efecto del j -ésimo del factor B (método de elaboración). El término γ_{ij} representa la interacción AB entre el i -ésimo nivel de A y el j -ésimo nivel de B. En forma matricial, el modelo (1) se expresa en la forma $Y = X\beta + \varepsilon$, donde Y y β tienen dimensiones 12×1 , mientras que X es una matriz cuadrada de 12×12 .

$$\begin{bmatrix} 39.02 \\ 38.8 \\ 35.74 \\ 35.4 \\ 37.02 \\ 36.0 \\ 38.96 \\ 39.0 \\ 35.58 \\ 35.5 \\ 35.7 \\ 36.0 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \gamma_{11} \\ \gamma_{12} \\ \gamma_{21} \\ \gamma_{22} \\ \gamma_{31} \\ \gamma_{32} \end{bmatrix} + \begin{bmatrix} \varepsilon_{111} \\ \varepsilon_{112} \\ \varepsilon_{211} \\ \varepsilon_{212} \\ \varepsilon_{311} \\ \varepsilon_{312} \\ \varepsilon_{121} \\ \varepsilon_{122} \\ \varepsilon_{221} \\ \varepsilon_{222} \\ \varepsilon_{321} \\ \varepsilon_{322} \end{bmatrix}$$

En este tipo de modelos es posible definir contrastes estimables en las interacciones γ_{ij} a partir de las columnas de X y $X'X$. Sin embargo, no es posible estimar contrastes que involucren las α 's y β 's solas. Por lo cual, para obtener un modelo que involucre diferencias entre estos parámetros es necesario promediar los contrastes y expresarlas como desviaciones de sus medias por lo cual, para probar la hipótesis de que el contenido de humedad promedio es la misma en los tres tipos de queso se define lo siguiente:

$$\alpha'_i = \alpha_i - \bar{\alpha}_{..} + \bar{\gamma}_{i.} - \bar{\gamma}_{..}$$

Por lo que la hipótesis $H_0: \alpha'_1 = \alpha'_2 = \alpha'_3$ se puede expresar como

$$H_0: \alpha_1 + \bar{\gamma}_{1.} = \alpha_2 + \bar{\gamma}_{2.} = \alpha_3 + \bar{\gamma}_{3.}$$

Expresado bajo sus promedios:

$$H_0: \alpha_1 + \frac{1}{2}(\gamma_{11} + \gamma_{12}) = \alpha_2 + \frac{1}{2}(\gamma_{21} + \gamma_{22}) = \alpha_3 + \frac{1}{2}(\gamma_{31} + \gamma_{32})$$

Bajo esta forma se pueden definir dos combinaciones: 1) la diferencia del efecto del queso tipo A y el efecto del queso tipo C es igual a 0. 2) la diferencia del efecto del queso tipo B y efecto del queso tipo C es igual a 0. Por lo cual, se tiene la siguiente expresión:

$$H_0: \begin{pmatrix} \left(\alpha_1 + \frac{1}{2}(\gamma_{11} + \gamma_{12}) \right) - \left(\alpha_3 + \frac{1}{2}(\gamma_{31} + \gamma_{32}) \right) \\ \left(\alpha_2 + \frac{1}{2}(\gamma_{21} + \gamma_{22}) \right) - \left(\alpha_3 + \frac{1}{2}(\gamma_{31} + \gamma_{32}) \right) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Reacomodando en el orden de los parámetros de la matriz de parámetros β se obtiene el juego de hipótesis para probar el efecto del tipo de queso, en la forma $H_0: C\beta = 0$:

$$H_0: \begin{pmatrix} \alpha_1 + \frac{1}{2}\gamma_{11} + \frac{1}{2}\gamma_{12} - \alpha_3 - \frac{1}{2}\gamma_{31} - \frac{1}{2}\gamma_{32} \\ \alpha_2 + \frac{1}{2}\gamma_{21} + \frac{1}{2}\gamma_{22} - \alpha_3 - \frac{1}{2}\gamma_{31} - \frac{1}{2}\gamma_{32} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$H_0: \begin{pmatrix} \alpha_1 - \alpha_3 + \frac{1}{2}\gamma_{11} + \frac{1}{2}\gamma_{12} - \frac{1}{2}\gamma_{31} - \frac{1}{2}\gamma_{32} \\ \alpha_2 - \alpha_3 + \frac{1}{2}\gamma_{21} + \frac{1}{2}\gamma_{22} - \frac{1}{2}\gamma_{31} - \frac{1}{2}\gamma_{32} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$C_1 = \begin{pmatrix} 0 & 1 & 0 & -1 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & 0 & 0 & -\frac{1}{2} & -\frac{1}{2} \\ 0 & 0 & 1 & -1 & 0 & 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Se utilizó la librería MASS para obtener la inversa generalizada X^tX . Resolviendo las ecuaciones normales del método de mínimos cuadrados $\hat{\beta} = (X^tX)^-X^tY$, se obtuvo lo siguiente:

$$\begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ \gamma_{11} \\ \gamma_{12} \\ \gamma_{21} \\ \gamma_{22} \\ \gamma_{31} \\ \gamma_{32} \end{bmatrix} = \begin{bmatrix} 18.44 \\ 7.51 \\ 5.25 \\ 5.67 \\ 9.30 \\ 9.14 \\ 3.64 \\ 3.87 \\ 2.56 \\ 2.69 \\ 3.08 \\ 2.58 \end{bmatrix}$$

Code

```
### 4. Efectos del factor A y B
(X_completo=as.matrix(problema2[,c(4,11:21)]))
      MU TA TB TC M1 M2 AM1 AM2 BM1 MB2 CM1 CM2
[1,]  1  1  0  0  1  0  1  0  0  0  0  0
[2,]  1  1  0  0  1  0  1  0  0  0  0  0
[3,]  1  0  1  0  1  0  0  0  1  0  0  0
[4,]  1  0  1  0  1  0  0  0  1  0  0  0
[5,]  1  0  0  1  1  0  0  0  0  0  1  0
[6,]  1  0  0  1  1  0  0  0  0  0  1  0
[7,]  1  1  0  0  0  1  0  1  0  0  0  0
[8,]  1  1  0  0  0  1  0  1  0  0  0  0
[9,]  1  0  1  0  0  1  0  0  0  1  0  0
[10,] 1  0  1  0  0  1  0  0  0  1  0  0
[11,] 1  0  0  1  0  1  0  0  0  0  0  1
[12,] 1  0  0  1  0  1  0  0  0  0  0  1
(Y=as.matrix(problema2[,1]))
# Rango de X
R(X_completo)
[1] 6
# Rango de X'X
(XtX_completo=t(X_completo)%*%X_completo)
R(XtX_completo)
[1] 6
> # Inversa generalizada de X'X (libreria MASS)
> (G_XtX_completo=ginv(XtX_completo))
> # Estimacion de parametros MCO
(betas_completo=G_XtX_completo%*%t(X_completo)%*%Y) #Esta solución no es única
      [,1]
[1,] 18.446667
[2,]  7.516667
[3,]  5.256667
[4,]  5.673333
[5,]  9.300833
[6,]  9.145833
[7,]  3.645833
[8,]  3.870833
[9,]  2.565833
[10,] 2.690833
[11,] 3.089167
[12,] 2.584167
```

Para identificar si C_1 es estimable, se verificó que $R(X) = R\begin{pmatrix} X \\ C_1 \end{pmatrix} \rightarrow 6 = 6$, por lo tanto, la combinación lineal C_1 sí es estimable.

$$X_{R1} = \begin{bmatrix} X \\ C_1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & -1 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & 0 & 0 & -\frac{1}{2} & -\frac{1}{2} \\ 0 & 0 & 1 & -1 & 0 & 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

Code

```
#Efecto del tipo de queso
#¿ES ESTIMABLE C?
> (C1=rbind(c(0,1,0,-1,0,0,1/2,1/2,0,0,-1/2,-1/2),
            c(0,0,1,-1,0,0,0,0,1/2,1/2,-1/2,-1/2)))
      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
[1,]    0    1    0   -1    0    0  0.5  0.5  0.0    0.0  -0.5  -0.5
[2,]    0    0    1   -1    0    0  0.0  0.0  0.5    0.5  -0.5  -0.5
(XC1=rbind(X_completo,C1))
      MU TA TB TC M1 M2 AM1 AM2 BM1 MB2 CM1 CM2
[1,]  1  1  0  0  1  0  1.0  0.0  0.0  0.0  0.0  0.0
[2,]  1  1  0  0  1  0  1.0  0.0  0.0  0.0  0.0  0.0
[3,]  1  0  1  0  1  0  0.0  0.0  1.0  0.0  0.0  0.0
[4,]  1  0  1  0  1  0  0.0  0.0  1.0  0.0  0.0  0.0
[5,]  1  0  0  1  1  0  0.0  0.0  0.0  0.0  1.0  0.0
[6,]  1  0  0  1  1  0  0.0  0.0  0.0  0.0  1.0  0.0
[7,]  1  1  0  0  0  1  0.0  1.0  0.0  0.0  0.0  0.0
[8,]  1  1  0  0  0  1  0.0  1.0  0.0  0.0  0.0  0.0
[9,]  1  0  1  0  0  1  0.0  0.0  0.0  1.0  0.0  0.0
[10,] 1  0  1  0  0  1  0.0  0.0  0.0  1.0  0.0  0.0
[11,] 1  0  0  1  0  1  0.0  0.0  0.0  0.0  0.0  1.0
[12,] 1  0  0  1  0  1  0.0  0.0  0.0  0.0  0.0  1.0
[13,] 0  1  0 -1  0  0  0.5  0.5  0.0  0.0 -0.5 -0.5
[14,] 0  0  1 -1  0  0  0.0  0.0  0.5  0.5 -0.5 -0.5
```

Code

```
R(X_completo)
[1] 6
R(XC1) #Es estimable
[1] 6
```

Posteriormente se obtuvo $R\hat{\beta}$, se observa que el diferencial no es cercano a 0.

Code

```
#Valores
(C1Beta=C1%%betas_completo)
      [,1]
[1,]  2.765
[2,] -0.625
```

El estadístico de prueba F se calculó de la siguiente forma

Code

```
#Prueba de F
(numerador_c1=t(C1Beta)%%inv(C1%%G_XtX_completo%%t(C1))%%C1Beta)
      [,1]
[1,] 26.03727
(rangonumerador_c1=R(inv(C1%%G_XtX_completo%%t(C1))))
[1] 2
PX_C=X_completo%%G_XtX_completo%%t(X_completo)
> R(PX_C)
[1] 6
I_C=as.matrix(diag(nrow(X_completo)))
(denominador_c=t(Y)%%(I_C-PX_C)%%Y)
      [,1]
[1,] 0.6512
(rangodenominador_c=R(I_C)-R(PX_C))
[1] 6
(Fc_tipo_queso=(numerador_c1/rangonumerador_c1)/(denominador_c/rangodenominador_c))
      [,1]
[1,] 119.9506
(Ftabla=qf(1-0.05,rangonumerador_c1,rangodenominador_c))
[1] 5.143253
(pvalue=1-pf(Fc_tipo_queso,rangonumerador_c1,rangodenominador_c))
      [,1]
[1,] 1.452688e-05
```

Con un $\alpha = 0.05$ y un valor $F_{calc} = 119.95$ superior a $F_{tablas} = 5.14$, se rechaza que H_0 , por lo cual, el efecto de al menos uno de los tipos de queso sobre el contenido de humedad del queso es diferente de 0, con un $p_{value} = 0.00014$.

Para probar la hipótesis de que el contenido de humedad promedio no es afectada por el método de elaboración se definieron los siguientes contrastes:

El efecto de B (método de elaboración) en el primer nivel de A (Queso Tipo A) esta expresado por:

$$\begin{aligned}\mu + \alpha_1 + \beta_1 + \gamma_{11} &= \mu + \alpha_1 + \beta_2 + \gamma_{12} \\ \therefore (\mu + \alpha_1 + \beta_1 + \gamma_{11}) - (\mu + \alpha_1 + \beta_2 + \gamma_{12}) &= 0 \\ \mu + \alpha_1 + \beta_1 + \gamma_{11} - \mu - \alpha_1 - \beta_2 - \gamma_{12} &= 0 \\ \beta_1 - \beta_2 + \gamma_{11} - \gamma_{12} &= 0\end{aligned}$$

El efecto de B en el segundo nivel de A (Queso tipo B) esta expresado por:

$$\begin{aligned}\mu + \alpha_2 + \beta_1 + \gamma_{21} &= \mu + \alpha_2 + \beta_2 + \gamma_{22} \\ \therefore (\mu + \alpha_2 + \beta_1 + \gamma_{21}) - (\mu + \alpha_2 + \beta_2 + \gamma_{22}) &= 0 \\ \mu + \alpha_2 + \beta_1 + \gamma_{21} - \mu - \alpha_2 - \beta_2 - \gamma_{22} &= 0 \\ \beta_1 - \beta_2 + \gamma_{21} - \gamma_{22} &= 0\end{aligned}$$

El efecto de B en el tercer nivel de A (Queso tipo C) esta expresado por:

$$\begin{aligned}\mu + \alpha_3 + \beta_1 + \gamma_{31} &= \mu + \alpha_3 + \beta_2 + \gamma_{32} \\ \therefore (\mu + \alpha_3 + \beta_1 + \gamma_{31}) - (\mu + \alpha_3 + \beta_2 + \gamma_{32}) &= 0 \\ \mu + \alpha_3 + \beta_1 + \gamma_{31} - \mu - \alpha_3 - \beta_2 - \gamma_{32} &= 0 \\ \beta_1 - \beta_2 + \gamma_{31} - \gamma_{32} &= 0\end{aligned}$$

Si estos tres efectos son iguales, no habría interacción. Si al menos uno difiere de otros dos, entonces se tiene una interacción. El juego de hipótesis puede ser expresado como: 1) el efecto del método de elaboración sobre el tipo de queso A es igual al efecto del tipo de queso B. 2) el

efecto del método de elaboración sobre el tipo de queso B es igual al efecto del tipo de queso C:

$$H_0: \begin{pmatrix} (\beta_1 - \beta_2 + \gamma_{11} - \gamma_{12}) - (\beta_1 - \beta_2 + \gamma_{21} - \gamma_{22}) \\ (\beta_1 - \beta_2 + \gamma_{21} - \gamma_{22}) - (\beta_1 - \beta_2 + \gamma_{31} - \gamma_{32}) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Reduciendo y acomodando los términos se obtiene:

$$H_0: \begin{pmatrix} \beta_1 - \beta_2 + \gamma_{11} - \gamma_{12} - \beta_1 + \beta_2 - \gamma_{21} + \gamma_{22} \\ \beta_1 - \beta_2 + \gamma_{21} - \gamma_{22} - \beta_1 + \beta_2 - \gamma_{31} + \gamma_{32} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$H_0: \begin{pmatrix} \gamma_{11} - \gamma_{12} - \gamma_{21} + \gamma_{22} \\ \gamma_{21} - \gamma_{22} - \gamma_{31} + \gamma_{32} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Se observa que el juego de hipótesis obtenido está únicamente en términos de las interacciones, las cuales están representadas en el modelo planteado originalmente con $\alpha_i, i = (1 \dots 6)$. Por lo cual, la prueba de hipótesis se realizó para el modelo completo y para el modelo reducido.

Para el modelo completo, en la forma $H_0: C\beta = 0$:

$$C_2 = \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Para identificar si C_2 es estimable, se verificó que $R(X) = R\begin{pmatrix} X \\ C_2 \end{pmatrix} \rightarrow 6 \neq 8$, por lo tanto, la combinación lineal C_2 no es estimable para el modelo completo.

$$X_{R1} = \begin{bmatrix} X \\ C_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 \end{bmatrix}$$

Code

```
#Efecto del método de elaboración
#¿ES ESTIMABLE C?
(C2=rbind(c(0,0,0,0,0,0,0,1,1,1,1,0,0),
           c(0,0,0,0,0,0,0,0,0,1,1,1,1)))
      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
[1,]    0    0    0    0    0    0    1    1    1    1    0    0
[2,]    0    0    0    0    0    0    0    0    1    1    1    1

(XC2=rbind(X_completo,C2))
      MU TA TB TC M1 M2 AM1 AM2 BM1 MB2 CM1 CM2
[1,]  1  1  0  0  1  0  1  0  0  0  0  0  0
[2,]  1  1  0  0  1  0  1  0  0  0  0  0  0
[3,]  1  0  1  0  1  0  0  0  0  1  0  0  0
[4,]  1  0  1  0  1  0  0  0  0  1  0  0  0
[5,]  1  0  0  1  1  0  0  0  0  0  0  1  0
[6,]  1  0  0  1  1  0  0  0  0  0  0  1  0
[7,]  1  1  0  0  0  1  0  1  0  0  0  0  0
[8,]  1  1  0  0  0  1  0  1  0  0  0  0  0
[9,]  1  0  1  0  0  1  0  0  0  0  1  0  0
[10,] 1  0  1  0  0  1  0  0  0  0  1  0  0
[11,] 1  0  0  1  0  1  0  0  0  0  0  0  1
[12,] 1  0  0  1  0  1  0  0  0  0  0  0  1
[13,] 0  0  0  0  0  0  1  1  1  1  0  0  0
[14,] 0  0  0  0  0  0  0  0  1  1  1  1  1
R(X_completo)
[1] 6
R(XC2) #No es estimable en el modelo completo
[1] 8
```

Para identificar si C_2 es estimable en el modelo de interacciones, en la forma $H_0: C\beta = 0$, con $\beta = \alpha_1, \alpha_2, \alpha_3, \alpha_4, \alpha_5, \alpha_6$. Se obtiene las siguientes combinaciones lineales:

$$H_0: \begin{pmatrix} \gamma_{11} - \gamma_{12} - \gamma_{21} + \gamma_{22} \\ \gamma_{21} - \gamma_{22} - \gamma_{31} + \gamma_{32} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \text{ es equivalente a:}$$

$$H_0: \begin{pmatrix} \alpha_1 - \alpha_4 - \alpha_2 + \alpha_5 \\ \alpha_2 - \alpha_5 - \alpha_3 + \alpha_6 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$H_0: \begin{pmatrix} \alpha_1 - \alpha_2 - \alpha_4 + \alpha_5 \\ \alpha_2 - \alpha_3 - \alpha_5 + \alpha_6 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$R_5 = \begin{pmatrix} 0 & 1 & -1 & 0 & -1 & 1 & 0 \\ 0 & 0 & 1 & -1 & 0 & -1 & 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

se verificó que $R(X) = R\begin{pmatrix} X \\ R_5 \end{pmatrix} \rightarrow 6 = 6$, por lo tanto, la combinación lineal R_5 si es estimable para el modelo de interacciones.

$$X_{R3} = \begin{bmatrix} X \\ R_5 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & -1 & 0 & -1 & 1 & 0 \\ 0 & 0 & 1 & -1 & 0 & -1 & 1 \end{bmatrix}$$

Code

```
## Es estimable en el modelo de interacciones
```

```
R5=rbind(c(0,1,-1,0,-1,1,0),
```

```
         c(0,0,1,-1,0,-1,1))
```

```
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    0    1   -1    0   -1    1    0
[2,]    0    0    1   -1    0   -1    1
```

```
(XR5=rbind(X,R5))
```

```
      MU ALPHA1 ALPHA2 ALPHA3 ALPHA4 ALPHA5 ALPHA6
[1,]    1      1      0      0      0      0      0
[2,]    1      1      0      0      0      0      0
[3,]    1      0      1      0      0      0      0
[4,]    1      0      1      0      0      0      0
[5,]    1      0      0      1      0      0      0
[6,]    1      0      0      1      0      0      0
[7,]    1      0      0      0      1      0      0
[8,]    1      0      0      0      1      0      0
[9,]    1      0      0      0      0      1      0
[10,]   1      0      0      0      0      1      0
[11,]   1      0      0      0      0      0      1
[12,]   1      0      0      0      0      0      1
[13,]   0      1     -1      0     -1      1      0
[14,]   0      0      1     -1      0     -1      1
```

```
R(X)
```

```
[1] 6
```

```
R(XR5) ##Es estimable
```

```
[1] 6
```

Posteriormente se obtuvo $R\hat{\beta}$, se observa que el diferencial es cercano a 0.

Code

```
#Valores
(R5Beta=R5%*%alphas)
      [,1]
[1,] -0.10
[2,] -0.63
```

El estadístico de prueba F se calculó de la siguiente forma

Code

```
#Prueba de F
(numerador5=t(R5Beta)%*%inv(R5%*%G_XtX%*%t(R5))%*%R5Beta)
      [,1]
[1,] 0.3132667
(rangonumerador5=R(inv(R5%*%G_XtX%*%t(R5))))
[1] 2
PX=X%*%G_XtX%*%t(X)
R(PX)
[1] 6
I=as.matrix(diag(nrow(X)))
(denominador=t(Y)%*%(I-PX)%*%Y)
      [,1]
[1,] 0.6512
(rangodenominador=R(I)-R(PX))
[1] 6
(Fc5=(numerador5/rangonumerador5)/(denominador/rangodenominador))
      [,1]
[1,] 1.443182
(Ftabla5=qf(1-0.05,rangonumerador5,rangodenominador))
[1] 5.143253
(pvalue=1-pf(Fc5,rangonumerador5,rangodenominador))
      [,1]
[1,] 0.3078091
```

Con un $\alpha = 0.05$ y un valor $F_{calc} = 1.4431$ inferior a $F_{tablas} = 5.14$, no se rechaza H_0 , por lo tanto, no hay efecto de método de elaboración sobre el contenido de humedad de queso, con un $p_{value} = 0.3078$.

5. Reparametrice el modelo utilizando variables dummy y pruebe 3) bajo el modelo reparametrizado

Se definió una variable dummy para el tipo de queso (DQ1, DQ2), dos variables dummy para el tipo de método (DM) y dos variables que representan la interacción:

Tipo de queso	Dqueso1	Dqueso2	Método de elaboración	Dmetodo
Tipo A	0	0	Método 1	0
Tipo B	1	0	Método 2	1
Tipo C	0	1		

Por lo cual, la matriz reparametrizada W con efecto de interacción es la siguiente

$$W = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 & 1 \end{bmatrix}$$

Los parámetros del modelo fueron estimados mediante la fórmula $(W^t W)^{-1} W^t Y$. El valor de cada parámetro fue:

$$\begin{bmatrix} \mu \\ D_{queso1} \\ D_{queso2} \\ D_{metodo} \\ D_{queso1}D_{metodo} \\ D_{queso2}D_{metodo} \end{bmatrix} = \begin{bmatrix} 38.91 \\ -3.34 \\ -2.4 \\ 0.07 \\ -0.1 \\ -0.73 \end{bmatrix}$$

Code

```
### 5. Reparametrización del modelo
(W=as.matrix(problema2[,c(4,11:13)]))
MU Dqueso1 Dqueso2 Dmetodo DM1 DM2
[1,] 1 0 0 0 0 0
[2,] 1 0 0 0 0 0
[3,] 1 1 0 0 0 0
[4,] 1 1 0 0 0 0
[5,] 1 0 1 0 0 0
[6,] 1 0 1 0 0 0
[7,] 1 0 0 1 0 0
[8,] 1 0 0 1 0 0
[9,] 1 1 0 1 1 0
[10,] 1 1 0 1 1 0
[11,] 1 0 1 1 0 1
[12,] 1 0 1 1 0 1
(alphas_est=inv(t(W)%*%W)%*%t(W)%*%Y)
[,1]
[1,] 38.91
[2,] -3.34
[3,] -2.40
[4,] 0.07
[5,] -0.10
[6,] -0.73
```

PROBLEMA 3

Suponga $Y \sim N(\mu, \Sigma)$ donde

$$\mu = [-1 \quad 0 \quad 3]$$

$$\Sigma = (0.75 \quad 0 \quad 0.25 \quad 0 \quad 1 \quad 0 \quad 0.25 \quad 0 \quad 0.75)$$

Y sea

$$A = (1.5 \quad 0 \quad -0.5 \quad 0 \quad 1 \quad 0 \quad -0.5 \quad 0 \quad 1.5)$$

Utiliza R o SAS para obtener

1. $E[Y^t A Y]$

Utilizando el siguiente teorema para la esperanza de sumas de cuadrados, si Y es un vector aleatorio con media μ y matriz de covarianza Σ , y si A es una matriz simétrica de constantes, entonces

$$E[Y^t A Y] = \text{tr}(A\Sigma) + \mu' A \mu$$

Por lo cual se realizaron las siguientes operaciones en Rstudio:

$$A = \begin{bmatrix} 1.5 & 0 & -0.5 \\ 0 & 1 & 0 \\ -0.5 & 0 & 1.5 \end{bmatrix}, \Sigma = \begin{bmatrix} 0.75 & 0 & 0.25 \\ 0 & 1 & 0 \\ 0.25 & 0 & 0.75 \end{bmatrix} \quad \mu = \begin{bmatrix} -1 \\ 0 \\ 3 \end{bmatrix}$$

Code

```
#### Problema 3
### 1. Definiendo las matrices
rm(list=ls())
(mu=matrix(c(-1,0,3),ncol = 1))
      [,1]
[1,]   -1
[2,]    0
[3,]    3
(sigma=matrix(c(0.75,0,0.25,0,1,0,0.25,0,0.75),ncol = 3))
      [,1] [,2] [,3]
[1,] 0.75  0 0.25
[2,] 0.00  1 0.00
[3,] 0.25  0 0.75
(A=matrix(c(1.5,0,-0.5,0,1,0,-0.5,0,1.5),ncol = 3))
      [,1] [,2] [,3]
[1,]  1.5  0 -0.5
[2,]  0.0  1  0.0
[3,] -0.5  0  1.5
```

Desglosando la formula se tiene lo siguiente:

$$A\Sigma = \begin{bmatrix} 1.5 & 0 & -0.5 \\ 0 & 1 & 0 \\ -0.5 & 0 & 1.5 \end{bmatrix} * \begin{bmatrix} 0.75 & 0 & 0.25 \\ 0 & 1 & 0 \\ 0.25 & 0 & 0.75 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\mu' A \mu = [-1 \quad 0 \quad 3] * \begin{bmatrix} 1.5 & 0 & -0.5 \\ 0 & 1 & 0 \\ -0.5 & 0 & 1.5 \end{bmatrix} * \begin{bmatrix} -1 \\ 0 \\ 3 \end{bmatrix} = 18$$

La traza de una matriz es la suma de los elementos de su diagonal, por lo tanto:

$$E[Y^t A Y] = \text{tr} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} + 18 = 3 + 18 = 21$$

Code

```
### 2. E(Y^t AY)= tr(AΣ)+ μ' Aμ
(AS=A%%sigma)
      [,1] [,2] [,3]
[1,]    1    0    0
[2,]    0    1    0
[3,]    0    0    1
(tr=sum(diag(AS)))
[1] 3
(mAm=t(mu)%%A%%mu)
[1] 18
(E=tr+mAm)
[1] 21
```

2. $V[Y^t A Y]$

La varianza de una forma cuadrática se obtiene mediante la siguiente formula

$$V[Y^t A Y] = 2\text{tr}[(A\Sigma)^2] + 4\mu' A \Sigma \mu$$

Desglosando la formula se tiene lo siguiente

$$(A\Sigma)^2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}^2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\mu' A \Sigma \mu = [-1 \quad 0 \quad 3] * \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} -1 \\ 0 \\ 3 \end{bmatrix} = 10$$

$$V[Y^t A Y] = (2 * 3) + (4 * 10) = 46$$

Code

```
### 3. V(Y^T A Y)= 2tr[(AΣ)^2 ]+4μ' AΣμ
(AS2=AS^2)
      [,1] [,2] [,3]
[1,]     1     0     0
[2,]     0     1     0
[3,]     0     0     1
(tr2=2*sum(diag(AS2)))
[1] 6
(Var=tr2+(4*t(mu)%*%AS%*mu))
[1] 46
```

3. ¿ $Y^t A Y$ se distribuye como una chi cuadrada? Explique y obtenga sus parámetros. ¿Es $A \Sigma$ una matriz idempotente?

Sea $y \sim N_p(\mu, \Sigma)$ con la forma cuadrática $Y^t A Y$ se distribuye $Y^t A Y \sim \chi^2_{[r, \frac{1}{2} \mu^t A \mu]}$ donde $r = \text{rango}[A]$, si y sólo si $A \Sigma$ es idempotente con rango r .

Los grados de libertad o el rango de la matriz $A = 3$, su parámetro de no centralidad $\frac{1}{2} \mu^t A \mu = \frac{1}{2} * 18 = 9$, Además, también el rango de la matriz $A \Sigma = 9$ y considerando que una matriz cuadrada A se dice que es idempotente si $AA = A$, se tiene lo siguiente:

$$A \Sigma = \begin{bmatrix} 1.5 & 0 & -0.5 \\ 0 & 1 & 0 \\ -0.5 & 0 & 1.5 \end{bmatrix} * \begin{bmatrix} 0.75 & 0 & 0.25 \\ 0 & 1 & 0 \\ 0.25 & 0 & 0.75 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\text{Idempotencia: } \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Por lo cual, se asume que $Y^t A Y$ se distribuye como una chi cuadrada con parámetros

$$Y^t A Y \sim \chi^2_{[3,9]}$$

Code

```
### 4. Se distribuye como x2?
library(matlib)
(R=R(A)) #grados de libertad
[1] 3

(NC=0.5*mAm) #No centralidad
[1] 946

¿AS tiene el mismo rango?
AS
      [,1] [,2] [,3]
[1,]    1    0    0
[2,]    0    1    0
[3,]    0    0    1

R(AS) → YT AY TIENE DISTRIBUCIÓN X2
[1] 3
```

4. Si $V[Y] = \sigma^2 I$ en lugar de $\Sigma = (0.75 \ 0 \ 0.25 \ 0 \ 1 \ 0 \ 0.25 \ 0 \ 0.75)$, ¿cuál sería la distribución de $\frac{Y^t AY}{\sigma^2}$? ¿Explique cuál es su parámetro de no centralidad y grados de libertad?

Sea $Y \sim N_n(\mu, \sigma^2 I)$ entonces, utilizando el teorema de Crochan

$$\frac{Y^t AY}{\sigma^2} = Y^t (A\sigma^{-2}) Y = Y^t D Y$$

Con

$$D = A\sigma^{-2}; \ V = \sigma^2 I$$

Note que DV es idempotente con rango $N - 1$

Por lo cual,

$$\frac{Y^t AY}{\sigma^2} = Y^t D Y \sim \chi^2_{[N-r, \lambda]}$$

Donde

$$\lambda = \frac{1}{2} \mu^t D \mu = \frac{1}{2} \mu^t \frac{A}{\sigma^2} \mu$$

Entonces

$$\frac{Y^t A Y}{\sigma^2} \sim x^2_{\left(N-r, \frac{1}{2} \mu^t \frac{A}{\sigma^2} \mu\right)}$$

En el que A es idempotente

$$\frac{Y^t A Y}{\sigma^2} \sim x^2_{(N-3,0)}$$

SCE se distribuye chi cuadrada central con N-r grados de libertad

Code

```
### 5. Distribución de Y'AY/sig2
#grados de libertad
R(A)
[1] 3

#Parametro de no centralidad
0.5*%t(mu)%*(A/sigma)%*mu
[1] 0
```

PROBLEMA 4

Considere los datos obtenidos de un estudio con dos factores desbalanceado

Alta proteína			Baja proteína		
Carne de res	Cereal	Carne de puerco	Carne de res	Cereal	Carne de puerco
73	98	94	90	107	49
102	74	79	76	95	82
56	90				

Suponga que queremos utilizar el modelo de dos vías de clasificación con interacción para analizar los datos. El modelo es:

$$y_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + \epsilon_{ijk}$$

$$i = 1, 2; j = 1, 2, 3; k = n_{ij}$$

$$\epsilon_{ijk} \sim iid N(0, \sigma^2)$$

$a = 2$ es el número de niveles del factor A (Nivel de proteína). $b = 3$ es el número de niveles del factor B (Tipo de alimento). n_{ij} es el tamaño de muestra de la combinación del nivel i del factor A con el nivel j del factor B . y_{ijk} representa la respuesta de la k -ésima rata que recibe el i -ésimo nivel de A y el j -ésimo nivel de B . α_i es el efecto asociado al i -ésimo nivel de A . β_j es un efecto asociado al j -ésimo nivel de B . $\alpha\beta_{ij}$ es efecto de interacción producido por la combinación del i -ésimo nivel de A con el j -ésimo nivel de B .

1. Escriba el modelo en la forma matriz/vector $Y = X\beta + \epsilon$, es decir, especifique Y , X , β y ϵ .

El modelo en la forma $Y = X\beta + \epsilon$ se compone de la siguiente forma:

$$Y = \begin{bmatrix} 73 \\ 102 \\ 56 \\ 98 \\ 74 \\ 90 \\ 94 \\ 79 \\ 90 \\ 76 \\ 107 \\ 95 \\ 49 \\ 82 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \alpha\beta_{11} \\ \alpha\beta_{12} \\ \alpha\beta_{13} \\ \alpha\beta_{21} \\ \alpha\beta_{22} \\ \alpha\beta_{23} \end{bmatrix} + \begin{bmatrix} \epsilon_{111} \\ \epsilon_{112} \\ \epsilon_{113} \\ \epsilon_{121} \\ \epsilon_{122} \\ \epsilon_{123} \\ \epsilon_{131} \\ \epsilon_{132} \\ \epsilon_{211} \\ \epsilon_{212} \\ \epsilon_{221} \\ \epsilon_{222} \\ \epsilon_{231} \\ \epsilon_{232} \end{bmatrix}$$

2. Del problema anterior considere que se midió el peso inicial y es posible que influya en el modelo el posible efecto del peso de cada rata al inicio del experimento (covariable) cuyos valores son:

Alta proteína			Baja proteína		
Carne de res	Cereal	Carne de puerco	Carne de res	Cereal	Carne de puerco
140	88	100	76	108	93
130	96	99	100	79	120
95	112				

Considere ahora el modelo de análisis de covarianza

$$y_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + \theta X_{ijk} + \varepsilon_{ijk}$$

$$i = 1,2; j = 1,2,3; k = n_{ij}$$

Donde X_{ijk} es el efecto de la covariable “peso inicial”. Escriba el modelo en la forma matriz/vector

$$Y = X\beta + \varepsilon$$

El nuevo modelo de covarianza es el siguiente:

$$Y = \begin{bmatrix} 73 \\ 102 \\ 56 \\ 98 \\ 74 \\ 90 \\ 94 \\ 79 \\ 90 \\ 76 \\ 107 \\ 95 \\ 49 \\ 82 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 140 \\ 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 130 \\ 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 95 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 88 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 96 \\ 1 & 1 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 112 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 100 \\ 1 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 99 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 76 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 100 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 108 \\ 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 79 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 93 \\ 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 1 & 120 \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \alpha\beta_{11} \\ \alpha\beta_{12} \\ \alpha\beta_{13} \\ \alpha\beta_{21} \\ \alpha\beta_{22} \\ \alpha\beta_{23} \\ \theta \end{bmatrix} + \begin{bmatrix} \varepsilon_{111} \\ \varepsilon_{112} \\ \varepsilon_{113} \\ \varepsilon_{121} \\ \varepsilon_{122} \\ \varepsilon_{123} \\ \varepsilon_{131} \\ \varepsilon_{132} \\ \varepsilon_{211} \\ \varepsilon_{212} \\ \varepsilon_{221} \\ \varepsilon_{222} \\ \varepsilon_{231} \\ \varepsilon_{232} \end{bmatrix}$$

5. ¿Cuál modelo parece más correcto para este estudio? Utilice una prueba de F parcial (modelo completo vs modelo reducido).

Modelo reducido - dos vías de clasificación con interacción

La suma de cuadrados del error (SC_{Er}) fue igual a 2207,667 con 8 grados de libertad. A continuación, se muestra la tabla ANOVA del modelo reducido:

	Df	Sum. Sq.	Media Sq.	F value	Pvalue
Proteína	1	0.02	0.02	0.0001	0.9928
Alimento	2	742.32	371.16	1.3450	0.3137
Proteína*Alimento	2	706.35	353.17	1.2798	0.3294
Residuales	8	2207.67	275.96		
SCM	5	1448.69			
SCT	13	3656.36			

Code

```
#Modelo reducido: No considera a la variable peso inicial
#-----
#Solución de ecuaciones normales
R(X_reducido)
X_reducido
      mu AP BP Res Cereal Puerco AP.Res AP.Cereal AP.Puerco BP.Res BP.Cereal BP.Puerco
[1,]  1  1  0  1      0      0      1      0      0      0      0      0
[2,]  1  1  0  1      0      0      1      0      0      0      0      0
[3,]  1  1  0  1      0      0      1      0      0      0      0      0
[4,]  1  1  0  0      1      0      0      1      0      0      0      0
[5,]  1  1  0  0      1      0      0      1      0      0      0      0
[6,]  1  1  0  0      1      0      0      1      0      0      0      0
[7,]  1  1  0  0      0      1      0      0      1      0      0      0
[8,]  1  1  0  0      0      1      0      0      1      0      0      0
[9,]  1  0  1  1      0      0      0      0      0      1      0      0
[10,] 1  0  1  1      0      0      0      0      0      1      0      0
[11,] 1  0  1  0      1      0      0      0      0      0      1      0
[12,] 1  0  1  0      1      0      0      0      0      0      1      0
[13,] 1  0  1  0      0      1      0      0      0      0      0      1
[14,] 1  0  1  0      0      1      0      0      0      0      0      1
XtX_red=t(X_reducido)%*%X_reducido
GXtX_red=ginv(XtX_red)
beta_hat_red=GXtX_red%*%t(X_reducido)%*%Y
#Formas cuadraticas
PX_red=X_reducido%*%GXtX_red%*%t(X_reducido)
J_red=matrix(1,nrow(PX_red),nrow(PX_red))
I_red=diag(1,nrow(X_reducido))
n_red=nrow(X_reducido)
#Suma de cuadrados total corregida
(SCT_red=t(Y)%*%(I_red-(1/n_red)*J_red)%*%Y)
      [,1]
[1,] 3656.357
#Grados de libertad totales
(glt_red=R(I_red-(1/n_red)*J_red)) #Son 14 observaciones
[1] 13
```

Code

```
#Suma de cuadrados del modelo
(SCM_red=t(Y)%*(PX_red-(1/n_red)*J_red)%*Y)
      [,1]
[1,] 1448.69
#Grados de libertad del modelo
(glm_red=R(PX_red-(1/n_red)*J_red))
[1] 5
#Suma de cuadrados del error
(SCE_red=t(Y)%*(I_red-PX_red)%*Y)
      [,1]
[1,] 2207.667
#Grados de libertad del error
(gle_red=R(I_red-PX_red))
[1] 8
#Cuadrado medio del modelo reducido
(CMM_red=SCM_red/glm_red)
      [,1]
[1,] 289.7381
#Cuadrado medio del error del modelo reducido
(CME_red=SCE_red/gle_red)
      [,1]
[1,] 275.9583
```

De acuerdo con la prueba de hipótesis para este modelo:

Ho: ninguno de los factores influye sobre Y

Ha: al menos uno de los factores influye sobre Y

Con un $\alpha = 0.05$, se obtuvo un valor $F_{calc} = 1.0499$ inferior a $F_t = 3.6874$ y un $pvalue = 0.4516$, no se rechaza H_0 , por lo cual los factores seleccionados para el modelo no explican a la variable de respuesta Y.

Code

```
#Cálculo de F
#Ho: ninguno de los factores influye sobre Y
#Ha: al menos un factor influye
(Fc_red=CMM_red/CME_red)
      [,1]
[1,] 1.049934
```

Code
<pre>#Valor de tablas y pvalue > (ftabla_red=qf(1-0.05,glm_red,gle_red)) [1] 3.687499 > (pvalue_red=1-pf(Fc_red,glm_red,gle_red)) [,1] [1,] 0.4516877 #No se rechaza Ho: por lo tanto #se asume que los factores proteína y tipo de alimento no #influyen sobre Y</pre>

Modelo completo – análisis de covarianza

La suma de cuadrados del error del modelo completo (SCEc) fue igual a 1117.43 con 7 grados de libertad. A continuación, se muestra la tabla de análisis de covarianza del modelo completo:

	Df	Sum. Sq.	Media Sq.	F value	Pvalue
Proteína	1	0.02	0.02	0.0001	0.9924
Alimento	2	742.32	371.16	1.5181	0.2834
Proteína*Alimento	2	1074.15	537.07	2.1967	0.1818
Peso inicial	1	128.44	128.44	0.5253	0.4921
Residuales	7	1711.43	244.49		
SCM	6	1944.93			
SCT	13	3656.36			

Code
<pre>###Modelo completo: Si considera a la variable peso inicial #----- X_completo mu AP BP Res Cereal Puerco AP.Res AP.Cereal AP.Puerco BP.Res BP.Cereal BP.Puerco Peso_inicial [1,] 1 1 0 1 0 0 1 0 0 0 0 0 0 140 [2,] 1 1 0 1 0 0 1 0 0 0 0 0 0 130 [3,] 1 1 0 1 0 0 1 0 0 0 0 0 0 95 [4,] 1 1 0 0 1 0 0 1 0 0 0 0 0 88 [5,] 1 1 0 0 1 0 0 1 0 0 0 0 0 96 [6,] 1 1 0 0 1 0 0 1 0 0 0 0 0 112 [7,] 1 1 0 0 0 1 0 0 1 0 0 0 0 100 [8,] 1 1 0 0 0 1 0 0 1 0 0 0 0 99 [9,] 1 0 1 1 0 0 0 0 0 1 0 0 0 76 [10,] 1 0 1 1 0 0 0 0 0 1 0 0 0 100 [11,] 1 0 1 0 1 0 0 0 0 0 1 0 0 108 [12,] 1 0 1 0 1 0 0 0 0 0 1 0 0 79 [13,] 1 0 1 0 0 1 0 0 0 0 0 1 0 93 [14,] 1 0 1 0 0 1 0 0 0 0 0 1 0 120</pre>

Code

```
#Solución de ecuaciones normales
R(X_completo)
[1] 7
XtX_comp=t(X_completo)%*%X_completo
GXtX_comp=ginv(XtX_comp)
beta_hat_comp=GXtX_comp%*%t(X_completo)%*%Y

#Formas cuadraticas
PX_comp=X_completo%*%GXtX_comp%*%t(X_completo)
J_comp=matrix(1,nrow(PX_comp),nrow(PX_comp))
I_comp=diag(1,nrow(X_completo))
n_comp=nrow(X_completo)
#Suma de cuadrados total corregida
(SCT_comp=t(Y)%*(I_comp-(1/n_comp)*J_comp)%*%Y)
      [,1]
[1,] 3656.357
#Grados de libertad totales
(glt_comp=R(I_comp-(1/n_comp)*J_comp)) #Son 14 observaciones
[1] 13
#Suma de cuadrados del modelo
(SCM_comp=t(Y)%*(PX_comp-(1/n_comp)*J_comp)%*%Y)
      [,1]
[1,] 1944.932
#Grados de libertad del modelo
(glm_comp=R(PX_comp-(1/n_comp)*J_comp))
[1] 6
#Suma de cuadrados del error
(SCE_comp=t(Y)%*(I_comp-PX_comp)%*%Y)
      [,1]
[1,] 1711.425
#Grados de libertad del error
(gle_comp=R(I_comp-PX_comp))
[1] 7
#Cuadrado medio del modelo completo
(CMM_comp=SCM_comp/glm_comp)
      [,1]
[1,] 324.1553
#Cuadrado medio del error del modelo completo
(CME_comp=SCE_comp/gle_comp)
      [,1]
[1,] 244.4893
```

De acuerdo con la prueba de hipótesis para este modelo:

H₀: ninguno de los factores influye sobre Y

H_a: al menos uno de los factores influye sobre Y

Con un $\alpha = 0.05$, se obtuvo un valor $F_{calc} = 1.3258$ inferior a $F_t = 3.8659$ y un $pvalue = 0.3571$, no se rechaza H_0 , por lo cual los factores y la variable seleccionada para el modelo no explican a la variable de respuesta Y.

Code

```
#Cálculo de F
#Ho: ninguno de los factores influye sobre Y
#Ha: al menos un factor influye
(Fc_comp=CMM_comp/CME_comp)
      [,1]
[1,] 1.325846
#Valor de tablas y pvalue
(ftabla_comp=qf(1-0.05,glm_comp,gle_comp))
[1] 3.865969
(pvalue_red=1-pf(Fc_comp,glm_comp,gle_comp))
      [,1]
[1,] 0.3571089
```

Comparación entre modelos

De acuerdo con las pruebas de F anteriores, ninguno de los dos modelos es adecuado para explicar a la variable de respuesta Y. Para evaluar si la variable peso inicial tiene un efecto sobre el modelo, se realizó la siguiente prueba de hipótesis:

H₀: la variable peso inicial no influye en el modelo

H_a: lo contrario

Para obtener la F parcial se utilizó la siguiente formula:

$$Fc_p = \frac{\frac{SCM_c - SCM_r}{glm_c - glm_r}}{CME_c} = 0.029705$$

Con un $\alpha = 0.05$ y un valor $F_{calc} = 2.029705$ inferior a $F_t = 5.5914$, no se rechaza H_0 , por lo tanto, la variable peso inicial no influye sobre el modelo, con un $pvalue = 0.1972$. Por lo cual, se

concluye que la selección de variables no fue adecuada para explicar a la variable Y. Aunque el modelo completo presenta un menor SCE y utilizando el criterio de Akaike el “mejor” modelo fue el modelo completo.

Code

```
###Comparando los modelos con F parcial
#-----
(SCM_peso=SCM_comp-SCM_red)
      [,1]
[1,] 496.2413
#Ho. la variable peso inicial no influye en el modelo
#Ha. lo contrario
(Fparcial=((SCM_comp-SCM_red)/(glm_comp-glm_red))/CME_comp)
      [,1]
[1,] 2.029705
(Ftabla_mod=(qf(1-0.05,glm_comp-glm_red,gle_comp)))
[1] 5.591448
(pvalueFp=1-pf(Fparcial,(glm_comp-glm_red),gle_comp))
      [,1]
[1,] 0.197271
#No se rechaza Ho: la variable peso inicial no influye
#sobre Y.

#para complementar, se obtuvo una grafica de dispersión
#Se observa que no hay correlacion entre ambas variables
cor(problema4$Y,problema4$Peso_inicial)
[1] 0.05855195

      df      AIC
modelo_red  7 124.5792
modelo_comp  8 123.0146
```

Problema 5

Considere el siguiente conjunto de datos con dos tratamientos medido sobre 4 vacas (2 para cada tratamiento) con 5 repeticiones medidas por vaca (es decir, 10 mediciones por tratamiento).

Tratamiento	Vaca	R ₁	R ₂	R ₃	R ₄	R ₅
1	A	451	456	462	449	455
1	B	472	469	476	467	462
2	C	481	475	482	489	483
2	D	510	502	499	507	501

1. Suponga el efecto de tratamiento fijo y el efecto vaca aleatorio. Escriba la matriz diseño X y Z de un modelo mixto.

El modelo lineal mixto puede ser presentado en la forma matricial $Y = X\beta + Zu + \varepsilon$:

$$Y_{ijk} = \mu + \tau_i + v_j + \varepsilon_{ijk} \quad Y \sim N(X\beta, ZGZ' + R) \quad u \sim N(0, G) \quad \varepsilon \sim n(0, R)$$

X es la matriz diseño para los efectos fijos del tratamiento τ_i ($i = 1, 2$). Z es la matriz diseño para los efectos aleatorios de la vaca v_j ($j = 1, \dots, 4$).

$$X\beta = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \end{bmatrix} \times \begin{bmatrix} \mu \\ \tau_1 \\ \tau_2 \end{bmatrix}; \quad Zu = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix} \times \begin{bmatrix} v_A \\ v_B \\ v_C \\ v_D \end{bmatrix}$$

Code

```
### matrices
problema5 <- read.csv("~/.../problema5.csv")
View(problema5)
X=model.matrix(~factor(problema5$Tratamiento)-1)
Z=model.matrix(~problema5$Vaca-1)
```

2. Suponga G es de varianza heterogénea. Ajuste el modelo mixto y obtenga los estimadores de ML y REML. Compare. Obtenga el BLUP e interprete. ¿Existe efecto del tratamiento?

Las matrices G y R son desconocidas, por lo cual se estimaron con el método de máxima verosimilitud (ML) y se comparó con la estimación por el método de máxima verosimilitud restringida (REML). La estructura general de la matriz G es:

$$G = \begin{bmatrix} \sigma_1^2 & 0 & 0 & 0 \\ 0 & \sigma_2^2 & 0 & 0 \\ 0 & 0 & \sigma_3^2 & 0 \\ 0 & 0 & 0 & \sigma_4^2 \end{bmatrix}$$

Para la construcción del modelo se utilizó la librería *nlme* (función “lme”).

Modelo mixto con ML

En los resultados se observa que los efectos aleatorios tuvieron una varianza residual, es decir, el error que se puede añadir a cada una de las predicciones fue de 4.9673 y la varianza de la constante fue de 9.006. Para cada tratamiento, la constante aumenta o disminuye por un valor aleatorio. Este valor aleatorio sigue una distribución normal con media esperada 0 y varianza 9.006. Para la parte de los efectos fijos del modelo, la constante se estima en 461.9 y el coeficiente para τ_2 fue de 31.0, con una varianza de 6.91 y 9.77, respectivamente. La correlación entre la constante y el tratamiento fue negativa con un valor de -0.707. No obstante, la tabla de anova muestra que el tratamiento no es significativo en el modelo, con un pvalue ligeramente superior a 0.05.

Code

```
### 1. ML VS REML
#-----
### 1. MODELO MIXTO CON EFECTO FIJO Y ALEATORIO - ML
mod1_ML=lme(Y ~ factor(Tratamiento), random = ~ 1|factor(Vaca), data =
problema5,method = "ML")
summary(mod1_ML)
Linear mixed-effects model fit by maximum likelihood
Data: problema5
      AIC      BIC    logLik
140.3077 144.2906 -66.15383
```

Code

Random effects:
Formula: ~1 | factor(Vaca)
(Intercept) Residual
StdDev: 9.006387 4.967394

Fixed effects: Y ~ factor(Tratamiento)
Value Std.Error DF t-value p-value
(Intercept) 461.9 6.914156 16 66.80497 0.0000
factor(Tratamiento)2 31.0 9.778093 2 3.17035 0.0867
Correlation:
(Intr)
factor(Tratamiento)2 -0.707

Standardized Within-Group Residuals:
Min Q1 Med Q3 Max
-1.53503419 -0.53062537 -0.06480027 0.67847916 1.45320831

Number of Observations: 20
Number of Groups: 4
ranef(mod1_ML) #BLUP
(Intercept)
A -6.881342
B 6.881342
C -10.274881
D 10.274881
fixef(mod1_ML) #BLUE
(Intercept) factor(Tratamiento)2
461.9 31.0

anova(mod1_ML)
numDF denDF F-value p-value
(Intercept) 1 16 9534.907 <.0001
factor(Tratamiento) 1 2 10.051 0.0867

Modelo mixto con REML

En los resultados se observa que los efectos aleatorios tuvieron una varianza residual de 4.9673, igual al modelo anterior, pero la varianza de la constante mayor, con un valor de 12.92. Para cada tratamiento, la constante aumenta o disminuye por un valor aleatorio. Este valor aleatorio sigue una distribución normal con media esperada 0 y varianza 12.92. Para la parte de los efectos fijos del modelo, la constante se estima en 461.9 y el coeficiente para τ_2 fue de 31.0, con una varianza de 9.27 y 13.11, respectivamente.

Code

```
### 2. MODELO MIXTO CON EFECTO FIJO Y ALEATORIO - REML
mod2_REML=lme(Y ~ factor(Tratamiento), random = ~ 1|factor(Vaca), data =
problema5,method = "REML")
summary(mod2_REML)
Linear mixed-effects model fit by REML
Data: problema5
      AIC      BIC    logLik
128.4946 132.0561 -60.24732

Random effects:
Formula: ~1 | factor(Vaca)
      (Intercept) Residual
StdDev:    12.92922  4.967394

Fixed effects: Y ~ factor(Tratamiento)
              Value Std.Error DF   t-value p-value
(Intercept)   461.9   9.276307 16  49.79352  0.0000
factor(Tratamiento)2   31.0 13.118679  2   2.36304  0.1419
Correlation:
              (Intr)
factor(Tratamiento)2 -0.707

Standardized Within-Group Residuals:
      Min      Q1      Med      Q3      Max
-1.47211191 -0.56728179 -0.03052213  0.63114318  1.44757403

Number of Observations: 20
Number of Groups: 4
ranef(mod2_REML) #BLUP
      (Intercept)
A    -7.090671
B     7.090671
C   -10.587440
D    10.587440
fixef(mod2_REML) #BLUE
(Intercept) factor(Tratamiento)2
      461.9              31.0
```

Comparación entre modelos ML vs REML

Utilizando el criterio de información de akaike (AIC) y el criterio de información bayesiano (BIC) se observa que el modelo con mejor ajuste fue el que utilizó el método de máxima verosimilitud restringida. Generalmente se prefieren las estimaciones REML de los componentes de la varianza, pues las estimaciones de ML podrían estar sesgadas, aunque tampoco se garantiza que las

estimaciones de REML sean insesgadas, pero en este caso se observa una notable diferencia en el desempeño de los modelos. Aproximadamente, la diferencia entre las estimaciones REML y ML de los componentes de la varianza es comparable a la estimación de σ^2 en una regresión de efectos fijos por $\frac{SSR}{(n-p)}$ vs $\frac{SSR}{n}$, donde SSR es la suma de cuadrados de los residuales. En ambos modelos la estimación de los coeficientes para los efectos fijos fue la misma.

			Code
AIC(mod1_ML,mod2_REML)			
	df	AIC	
mod1_ML	4	140.3077	
mod2_REML	4	128.4946	
BIC(mod1_ML,mod2_REML)			
	df	BIC	
mod1_ML	4	144.2906	
mod2_REML	4	132.0561	
fixef(mod1_ML) #BLUE			
	(Intercept)	factor(Tratamiento)2	
	461.9	31.0	
fixef(mod2_REML) #BLUE			
	(Intercept)	factor(Tratamiento)2	
	461.9	31.0	

Estimaciones de BLUE y BLUP.

Los valores de BLUP estimados para ambos modelos fueron los siguientes

Vaca	ML	REML
Vaca A	-6.881342	-7.0906
Vaca B	6.881342	7.0906
Vaca C	-10.2748	-10.5874
Vaca D	10.2748	10.5874

Se observa que con el método de ML existe una ligera subestimación del efecto aleatorio que ejerce cada vaca sobre la variable de respuesta. Los individuos del tratamiento dos muestran un mayor efecto sobre el intercepto del modelo.

Modelo reducido vs completo: Efecto del individuo

Para evaluar el efecto del componente aleatorio se ajustó un nuevo modelo reducido sin el término aleatorio y se comparó con el modelo original, este modelo es equivalente a un modelo lineal tradicional, pero utilizando un estimador REML mediante la función *gls*. Las comparaciones de modelos, estimados bajo el mismo método, a partir de pruebas de razón de verosimilitud se obtienen con la función *anova*. Se utilizó el método REML para la comparación para evitar una mala estimación del pvalue asociada al problema del límite.

Con la función *anova* se determina la contribución de un único factor al comparar el ajuste (medido como -2 veces el ratio del logaritmo de la verosimilitud) para modelos con y sin un factor, que es lo que se conoce como modelos anidados. Este test implica una medida relativa de la bondad de ajuste perdida o ganada en el modelo al incluir el factor.

Bajo la prueba de hipótesis: H_0 : el efecto aleatorio no influye sobre el modelo. H_a : lo contrario. Con un L.ratio significativo ($pvalue < 0.05$) se rechaza H_0 y se concluye que es importante incluir el efecto del individuo en el ajuste del modelo. Asimismo, el valor obtenido del modelo AIC y BIC fue menor para el modelo completo. Esto además sugiere que existe un efecto general significativo de la vaca evaluada sobre la variable de respuesta.

Code

```
### 2. MODELO COMPLETO VS REDUCIDOS
#-----
### 1. MODELO MIXTO SIN EFECTO ALEATORIO - REML
mod3_reduc=gls(Y ~ factor(Tratamiento), data = problema5,method = "REML")
summary(mod3_reduc)
Generalized least squares fit by REML
Model: Y ~ factor(Tratamiento)
Data: problema5
      AIC      BIC    logLik
147.4897 150.1608 -70.74483

Coefficients:
                Value Std.Error  t-value p-value
(Intercept)      461.9   3.428476 134.7246      0
factor(Tratamiento)2  31.0   4.848597   6.3936      0

Correlation:
                (Intr)
factor(Tratamiento)2 -0.707
```

Code

Standardized residuals:

Min	Q1	Med	Q3	Max
-1.651018643	-0.936192135	0.009223568	0.770167914	1.577230100

Residual standard error: 10.84179

Degrees of freedom: 20 total; 18 residual

anova(mod3_reduc,mod2_REML)

Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
mod3_reduc	1	3	147.4897	150.1608	-70.74483		
mod2_REML	2	4	128.4946	132.0561	-60.24732	1 vs 2	20.99502 <.0001

Modelo reducido vs completo: Efecto del tratamiento

Para evaluar el efecto del componente fijo, se ajustó un nuevo modelo reducido sin el término fijo y se comparó con el modelo original. En este caso, la comparación de modelos que difieren en su componente se debe hacer con el método ML, pues no es posible hacer la comparación con el método REML, por lo que se compararon los modelos a partir del método de máxima verosimilitud. No obstante, este tipo de test no es muy fiable para comprobar la significancia de efectos fijos cuando hay tamaños de muestra pequeños.

Bajo la prueba de hipótesis: H_0 : el efecto fijo no influye sobre el modelo. H_a : lo contrario. Con un $pvalue < 0.05$ se rechaza H_0 y se concluye que el tratamiento si explica la variabilidad sustancial además de la atribuida al componente aleatorio, por lo tanto, es importante incluir el efecto del tratamiento en el ajuste del modelo.

Code					
### 2. MODELO SIN EFECTO FIJO (Modelo anidado)					
mod4_red=lme(Y~1, random = ~1 Vaca,method = "ML",data = problema5)					
summary(mod4_red)					
Linear mixed-effects model fit by maximum likelihood					
Data: problema5					
	AIC	BIC	logLik		
	143.6392	146.6264	-68.81961		
Random effects:					
Formula: ~1 Vaca					
	(Intercept)	Residual			
StdDev:	17.92666	4.967394			

Code

Fixed effects: Y ~ 1

	Value	Std.Error	DF	t-value	p-value
(Intercept)	477.4	9.266522	16	51.51879	0

Standardized Within-Group Residuals:

	Min	Q1	Med	Q3	Max
	-1.47441863	-0.56100847	-0.02706124	0.58517727	1.42319522

Number of Observations: 20

Number of Groups: 4

anova(mod4_red,mod1_ML)

	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
mod4_red	1	3	143.6392	146.6264	-68.81961			
mod1_ML	2	4	140.3077	144.2906	-66.15383	1 vs 2	5.331555	0.0209

Sin embargo, de acuerdo con el análisis de varianza para los modelos completos estimados con ML y REML, el efecto aleatorio de cada individuo podría enmascarar el efecto real del tratamiento, pues en ambos métodos se observa un pvalue > 0.05 para el tratamiento.

Code					
#Estimado con ML					
anova(mod1_ML)					
	numDF	denDF	F-value	p-value	
(Intercept)	1	16	9534.907	<.0001	
factor(Tratamiento)	1	2	10.051	0.0867	
#Estimado con REML					
anova(mod2_REML)					
	numDF	denDF	F-value	p-value	
(Intercept)	1	16	5297.178	<.0001	
factor(Tratamiento)	1	2	5.584	0.1419	

Variabilidad explicada

En los modelos mixtos es complicado estimar la variabilidad explicada por el modelo debido a que a los efectos fijos hay que añadirle un error atribuible al factor aleatorio. Con la función “r.squaredGLMM” de la librería *MuMIn* se puede obtener el coeficiente de determinación o

variabilidad explicada por el modelo, tanto para la parte de efectos fijos como para el modelo completo, incluyendo los efectos aleatorios.

La función da dos R^2 , el primero es R^2 marginal, que hace referencia a la cantidad de variabilidad explicada por los efectos fijos, y el segundo es R^2 condicional, que hace referencia a la variabilidad explicada por el modelo completo, incluyendo los efectos aleatorios.

Se observa que con el estimador REML, el modelo explica una mayor variabilidad en el modelo completo, con un $R_c^2 = .94$, respecto a ML que obtuvo un valor $R_c^2 = 0.93$. El coeficiente de determinación marginal obtenida en ambos modelos indica que el modelo con el estimador ML explica mejor la variabilidad por los efectos fijos, sin embargo, el tamaño de muestra es pequeño y esta estimación puede estar sesgada por el tamaño de muestra.

Code

```
#Con el estimador ML
r.squaredGLMM(mod1_ML)
      R2m      R2c
[1,] 0.7050613 0.931207
#Con el estimador REML
r.squaredGLMM(mod2_REML)
      R2m      R2c
[1,] 0.5686421 0.9445174
```

PROBLEMA

Reanalice el modelo de curvas de crecimiento del artículo anexo (Tabla 4) utilizando regresión no lineal en R o Solver de Excel. *Growth curve of commercial broiler as predicted by different nonlinear functions.*

Descripción del estudio

El objetivo del estudio fue identificar la mejor función que se ajusta a la curva de crecimiento en pollos de engorda. El crecimiento puede definirse como un aumento del tamaño corporal por unidad de tiempo. La aplicación de ecuaciones no lineales en la curva de crecimiento proporcionará un conjunto de parámetros que podrían utilizarse para describir el patrón de crecimiento a lo largo del tiempo.

Metodología

El experimento se llevo a cabo en el periodo 06/04/2015 a 17/05/2015. Se les suministro a las aves una dieta básica comercial y su peso se registró a intervalos fijos de una semana durante seis semanas. Las curvas de crecimiento se realizaron con los pesos corporales semanales y se utilizaron tres funciones:

$$WLS = \frac{\beta_0}{1 + \exp(-\beta_1 - \beta_2 X)}$$

$$Gompertz = \beta_0 * \exp(-\beta_1 * \exp(-\beta_2 X))$$

$$Logistico = \frac{\beta_0}{(1 + \beta_1 * \exp(\beta_2 X))}$$

En todas las funciones, β_0 es el parámetro de peso asintótico, β_1 es el parámetro de escala (constante de integración) y β_2 es el parámetro de la tasa de crecimiento instantáneo. Los datos proporcionados por los autores fueron los siguientes

Semana	Estimado	Parámetros	β_0	β_1	β_2
0	43.00	WLS	2088	-3.68	0.14
1	146.88	Gompertz	2814	4.83	0.06
2	377.55	Logistico	2186	0.13	33.49
3	710.83				
4	1228.55				
5	1650.00				
6	1955.10				


Procedimiento en Solver



Se utilizó la función Solver en Excel para obtener los parámetros $\beta_0, \beta_1, \beta_2$. En primer lugar, se obtuvieron los valores predichos aplicando cada una de las ecuaciones de crecimiento, posteriormente se obtuvo la suma de cuadrados del error (SCR) y se especificó en la función solver la minimización de SCR. Como valores iniciales de semilla, se utilizaron los valores de $\beta_0, \beta_1, \beta_2$ proporcionados en el artículo. Los valores de los parámetros estimados mediante el método de mínimos cuadrados, así como la comparación entre los valores estimados y predichos para cada tipo de función se muestran a continuación:

Parámetros	SCR	β_0	β_1	β_2
WLS	1544.56	2191.9488	-3.4965	0.9291
Gompertz	4803.92	2820.89	4.8234	0.4338
Logístico	1544.56	2191.98	32.99	0.9291

Semana	Estimado	Predicho WLS	Predicho Gompertz	Predicho Logístico
0	43.00	64.468	22.677	64.476
1	146.88	156.222	123.858	156.235
2	377.55	356.670	372.1585	356.685
3	710.83	722.971	759.194	722.980
4	1228.55	1216.175	1205.022	1216.170
5	1650.00	1664.578	1625.603	1664.571
6	1955.10	1948.218	1973.647	1948.223

A continuación, se muestran las curvas de crecimiento de cada modelo.





Al igual que en el artículo, los valores de β_0 más altos se obtuvieron con la función Gompertz, mientras que las funciones WLS y logística mostraron valores similares. En este caso, los valores más altos de β_1 se obtuvieron con el modelo logístico y los valores más bajos se obtuvieron con la función WLS. Respecto a β_3 , los valores obtenidos por la función WLS y logística fueron los mismos, al igual que la suma de cuadrados de los residuales.